Aprendizaje automático aplicado a la predicción de desviaciones de tiempo de producción en un entorno *job-shop* con integración ERP-MES

19 Oct 2026

Universidad Internacional de Valencia

Titulación:
Inteligencia Artificial
Curso académico
2025 – 2026

Alumno/a:
Montanera Llata, Jaume
D.N.I: 53867226F
Directora TFM
Jacky Barraza

Convocatoria:
Primera

De:
Planeta Formación y Universidades

Universidad Internacional de Valencia

Abstract

In the fabrics world ERP systems plan production using static standard times that rarely match the actual times recorded by the MES systems. This thesis examines whether historical data from both systems can predict that deviation at the operation level in a machining job shop, where the same operation can run on several equivalent machines. The approach is predictive rather than prescriptive: given an operation–machine assignment, the model estimates the expected deviation, and the decision stays with the planner.

Following the CRISP-DM methodology, fourteen months of ERP and MES data from a real plant were integrated. After cleaning, the final dataset contains over 14,000 operations across nine machine families. The target is the ratio between effective actual time and planned time. The typical operation takes about 50% longer than planned. Ridge regression, Random Forest and LightGBM were trained on both the ratio and its logarithm, using time-based cross-validation. They were compared against three baselines: the current ERP plan, a global bias correction and a per-machine correction.

The selected model, LightGBM trained on the log ratio, reduces mean absolute error on the test set by 23% relative to the ERP plan. This exceeds the 20% threshold set as the hypothesis, and the model also improves on the per-machine correction by 9%. Measured in minutes, the improvement is 16.6%. SHAP analysis identifies planned time as the most influential variable. Short operations deviate the most, which suggests a fixed per-operation time that the ERP does not account for. The remaining error indicates that performance is limited by the available information rather than by the model.

Keywords: ERP, MES, machine learning, production time prediction, job shop, LightGBM.

Universidad Internacional de Valencia

Resumen

En entornos de fabricación los sistemas ERP planifican la producción con tiempos teóricos estáticos que rara vez coinciden con los tiempos reales capturados en registros de sistemas MES. Este trabajo estudia si los datos históricos de ambos sistemas permiten predecir esa desviación a nivel de fase, en un taller de mecanizado (*job-shop*) donde una misma fase puede ejecutarse en varias máquinas equivalentes. El enfoque es predictivo y no prescriptivo: dada una asignación de fase a máquina, el modelo estima la desviación esperada, y la decisión final sigue en manos del planificador.

Siguiendo la metodología CRISP-DM, se integraron catorce meses de datos de ERP y MES de una planta real. Tras depurar los registros, el conjunto final contiene más de 14.000 fases de fabricación, repartidas en nueve familias de máquinas. La variable objetivo es el ratio entre el tiempo real efectivo y el tiempo teórico. La fase típica tarda en torno a un 50% más de lo previsto. Se compararon Ridge, Random Forest y LightGBM, entrenados sobre el ratio y sobre su logaritmo, con validación cruzada temporal. Como referencia se usaron tres baselines: la planificación actual del ERP, una corrección global del sesgo y una corrección del sesgo por máquina.

El modelo seleccionado, LightGBM sobre el logaritmo del ratio, reduce en test el error absoluto medio un 23% respecto al ERP. Supera así el umbral del 20% fijado como hipótesis, y mejora un 9% a la corrección de sesgo por máquina. Expresada en minutos, la mejora es del 16,6%. Las fases de fabricación cortas son las que más se desvían, lo que sugiere un tiempo fijo por fase que el ERP no contempla. El error restante indica que el límite está en la información disponible más que en el modelo.

Palabras clave: ERP, MES, aprendizaje automático, predicción de tiempos de producción, *job-shop*, LightGBM.

Universidad Internacional de Valencia

Índice

1. Introducción 1
2. Marco teórico 4
3. Estado del Arte 8
4. Metodología 13
    4.1 Comprensión del negocio 13
        4.1.1 Contexto del negocio 13
        4.1.2 Definición del problema 13
        4.1.3 Supuestos, restricciones y riesgos 15
    4.2 Comprensión de los datos 16
        4.2.1 Estructura de la información en ERP y MES 16
        4.2.2 Origen y recopilación de los datos 17
        4.2.3 Descripción de los datos 18
        4.2.4 Exploración Inicial 19
        4.2.5 Verificación de la calidad de los datos 23
    4.3 Preparación de los datos 23
        4.3.1 Selección de datos 23
        4.3.2 Limpieza de los datos 26
        4.3.3 Preprocesamiento de datos 27
        4.3.4 Construcción de la variable objetivo 29
        4.3.5 Conjunto final 32
        4.3.6 Justificación viabilidad de los datos 35
    4.4 Modelado 36
        4.4.1 Planteamiento del problema de modelado 36
        4.4.2 Variable objetivo: ratio frente a logaritmo del ratio 36
        4.4.3 Estrategia de validación y métricas 37
        4.4.4 Baseline 42
        4.4.5 Modelos considerados 47
        4.4.6 Comparaciones 56
    4.5 Evaluación 59
        4.5.1 Métricas MAE y RMSE los modelos 59
        4.5.2 Skill score MAE 60
        4.5.3 Interpretabilidad de LightGBM-log 60
        4.5.4 Análisis por segmentos LightGBM-log 64
    4.6 Despliegue 71
5. Cierre del trabajo 72
    5.1 Conclusiones 72
    5.2 Limitaciones 74
    5.3 Trabajo futuro 75
6. Referencias 76

Índice de ilustraciones

Ilustración 1: Tabla evolución de los sistemas de gestión industriales [Guo et al. 2022].
Ilustración 2: Muestra las distintas ramas de ML y su aplicabilidad en ERP [Jawad & Balázs, 2024]
Ilustración 3: Muestra las distintas ramas del ML y su enfoque en entornos PCC
Ilustración 4: Dibujo del flujo digital de fabricación de las distintas entidades a relacionarse entre ERP y MES.
Ilustración 5: Descripción de las tablas de datos tomadas en el estudio.
Ilustración 6: Número de instancias por tabla.
Ilustración 7: Número de instancias por tablas
Ilustración 8: Fases según el número de máquinas en que se imputaron
Ilustración 9: Distribución de las imputaciones en los grupos de máquinas originales
Ilustración 10: Los 7 grupos de máquinas con menos imputaciones
Ilustración 11: Tabla de artículos
Ilustración 12: Tabla del reparto de instancias entre las tablas en el intervalo de estudio
Ilustración 13: Tabla con la evolución de la población de estudio para las máquinas
Ilustración 14: Instancias resultantes tras la limpieza
Ilustración 15: Tabla de contenido con las variables del tiempo teórico
Ilustración 16: Tabla de contenido con variables creadas
Ilustración 17: Variables de tiempo para calcular el ratio
Ilustración 18: Distribución del ratio
Ilustración 19: Inspección de las colas
Ilustración 20: Inspección de colas en base los tiempos previstos
Ilustración 21: Distribución del ratio por familia (grupo) de máquinas
Ilustración 22: Evolución temporal del ratio
Ilustración 23: Recuento de máquinas por familias
Ilustración 24: Población de estudio final
Ilustración 25: Tabla de atributos finales
Ilustración 26: Distribución del ratio y del logaritmo del ratio
Ilustración 27: Tabla resumen variable objetivo ratio vs logaritmo
Ilustración 28: Reparto de fases y órdenes de fabricación por mes
Ilustración 29: Reparto de las fases entre desarrollo y test
Ilustración 30: Validación cruzada reparto de folds
Ilustración 31: Fases descartadas por umbral de corte
Ilustración 32: Distribución del ratio entre las dos escalas con umbrales de corte aplicados
Ilustración 33: Tabla resumen de los baselines para entender su objetivo
Ilustración 34: Estudio del MAE y RMSE para el baseline B0 en validación y test
Ilustración 35: Estudio del error medio de MAE para B0 en validación y test
Ilustración 36: Estudio del MAE y RMSE para el baseline B1 en validación y test
Ilustración 37: Inspección orientativa de las variables consideradas en train

Ilustración 38: Estudio del MAE y RMSE para el baseline B2 en validación y test
Ilustración 39: Mediana del ratio por familias para los datos de desarrollo
Ilustración 40: evolución del MAE y RMSE para cada baseline
Ilustración 41: Variables de entrenamiento
Ilustración 42: Resultados validación para el modelo Ridge
Ilustración 43: Descripción de la media y mediana para el ratio real y las inferencias
Ilustración 44: Evolución del hiperparámetro para las hojas del árbol.
Ilustración 45: Resultados validación para el modelo Random Forest
Ilustración 46: Resultados para num_leaves y min_child_samples con L2 ratio
Ilustración 47: Resultados de num_leaves con L2 ratio
Ilustración 48: Resultados para num_leaves y min_child_samples con L2 log(ratio)
Ilustración 49: Resultados de num_leaves con L2 log(ratio)
Ilustración 50: Resultados para num_leaves y min_child_samples con L1 ratio
Ilustración 51: Posibles configuraciones con resultados LightGBM
Ilustración 53: Tabla resumen de MAE para los modelos y los baselines en cada fold
Ilustración 55: Tabla resumen del skill score para B0 en cada fold
Ilustración 56: MAE y RMSE en test para cada modelo y baseline
Ilustración 58: Evolución del error para los 14 meses
Ilustración 59: Resultados del peso de las variables al aplicar SHAP en el modelo
Ilustración 60: Resultados del peso de las variables al aplicar SHAP en el modelo
Ilustración 61: Representación de la dirección SHAP hacia la que empuja la variable
Ilustración 62: Distribución del error por familia de máquinas en test
Ilustración 63: Distribución del skill score por familia de máquinas en test
Ilustración 64: Tabla comparativa MAE y skill score para la máquina no vista en entrenamiento
Ilustración 65: Agrupación de las fases en test por tramo duración
Ilustración 66: Distribución de MAE por tramo duración en las fases de test
Ilustración 67: Distribución del skill score por tramo duración en las fases de test
Ilustración 68: Fórmulas para trabajar desde el ratio a minutos
Ilustración 69: Descripción del error en minutos para el modelo y cada baseline
Ilustración 70: Distribución del error en minutos para cada grupo de fases en base su duración teórica

1. Introducción

La industria manufacturera se encuentra inmersa en un proceso de digitalización profunda. Bajo el paraguas de la Industria 4.0, las plantas de producción generan y almacenan cada vez más datos sobre su propio funcionamiento: qué se fabrica, cuándo, en qué máquina y con qué resultado. Sin embargo, disponer de datos no equivale a sacarles partido. En muchas empresas, esta información se registra con fines de control y trazabilidad, pero no siempre se aprovecha todo su potencial como fuente de información para la planificación de la producción.

Dos sistemas de información concentran la mayor parte de estos datos. El primero es el ERP (*Enterprise Resource Planning*), el software de gestión que centraliza la información de la empresa. En él conviven pedidos, materiales, rutas de fabricación, es donde se construye la planificación de la producción. Entre otras cosas, el ERP contiene los tiempos teóricos, cuánto *debería* tardar cada operación. El segundo es el MES (*Manufacturing Execution System*), el sistema que acompaña la ejecución a pie de planta y registra lo que *realmente* ocurre. Captura qué operación se ha hecho, en qué máquina, cuánto ha durado y quién la ha realizado. [Scholten & Brandl, 2022].

En síntesis, el ERP planifica y el MES registra la realidad. Y entre ambos aparece, de manera sistemática, una diferencia: los tiempos reales rara vez coinciden con los teóricos. Esta desviación introduce incertidumbre en la planificación y, en particular, en la asignación de fases de producción a máquinas, donde una misma operación puede ejecutarse en diferentes equipos con resultados de tiempo distintos.

En las últimas décadas los sistemas ERP han sido la columna vertebral de la gestión empresarial, simplificando procesos y centralizando la información de la organización. [Katuu 2020]. Sin embargo, presentan limitaciones conocidas en el ámbito de la planificación de producción. Una de las más señaladas en la literatura es la generación de planes poco realistas o inviables, derivada de una programación a capacidad infinita [Oluyisola et al., 2022]. Asimismo, los tiempos teóricos con los que trabaja el ERP son estimaciones estáticas que no recogen la variabilidad real del taller. El contraste entre ambas fuentes, lo previsto en el ERP y lo ejecutado según el MES, es precisamente donde reside la desviación que este trabajo pretende modelar.

La irrupción del *aprendizaje automático* en el entorno industrial ha transformado el modo de explotar estos datos. La integración de técnicas de *Machine Learning* en los sistemas ERP permite convertirlos en plataformas de soporte a la decisión basadas en datos [Gaol et al. 2023], y los propios fabricantes de software (SAP y Oracle principalmente) incorporan progresivamente estas capacidades en sus productos.

Ahora bien, la literatura también advierte de dificultades. La calidad y limpieza de los datos, la elección del algoritmo adecuado para cada caso, y el hecho de que un método que funciona en un conjunto de datos puede no funcionar en otro, aunque estos sean similares [Oluyisola et al., 2022].

Este trabajo se plantea desde una premisa deliberada, no se aborda como un problema de optimización. La asignación de fases a máquinas podría formularse como

un problema de programación de la producción con elegibilidad de máquinas, conocido en la literatura como del tipo *flexible job-shop* (FJSP), pero esta vía presenta dos inconvenientes en el contexto real de una planta. Por un lado, estos problemas son matemáticamente intratables en la práctica, lo que hace inviable el uso de algoritmos exactos [Dauzère-Pérès et al. 2024]. Por otro lado, exigiría modelar explícitamente todas las restricciones del taller y evaluar una asignación mediante una única función objetivo. En la práctica el tiempo no es la única variable que define una mejor asignación de trabajo en máquina: intervienen también la calidad, el coste, la disponibilidad de utillaje o la experiencia del operario [Đurasević y Jakobović 2018].

En su lugar, este trabajo adopta un enfoque predictivo, no prescriptivo. La diferencia es sustancial: un sistema prescriptivo respondería a la pregunta *"¿en qué máquina debe ejecutarse esta fase?"*, tomando la decisión en lugar del planificador; un sistema predictivo responde a otra distinta: *"si esta fase se ejecuta en esta máquina, ¿qué desviación cabe esperar entre el tiempo estimado y el real?"*. El modelo propuesto pertenece a esta segunda categoría, dada una asignación concreta de fase a máquina, estima la desviación esperada a partir del comportamiento histórico registrado en los sistemas ERP y MES.

El valor de esta señal no está en sustituir el criterio del planificador, sino en reducir la incertidumbre con la que trabaja. La decisión final sigue siendo humana, y así debe ser. La persona planificadora maneja información que el modelo entrenado sobre datos históricos no posee, la urgencia de un pedido, la disponibilidad de un utillaje, el estado de un operario. El sistema no toma decisiones en lugar del usuario, le proporciona herramientas para tomarlas mejor fundamentadas [Jawad y Balázs 2024]. Este planteamiento es, además, coherente con casos observados en la práctica industrial. Los usuarios de planificadores están más dispuestos a trabajar con herramientas simples y flexibles en vez de métodos complejos, aunque estos sean teóricamente superiores. [de Man y Strandhagen 2018].

El caso práctico sobre el que se desarrolla este trabajo es una planta de mecanizados que dispone de distintas familias de máquinas, donde cada familia agrupa equipos de características similares. Una misma fase de producción puede ejecutarse en cualquiera de las máquinas de su familia. Esta tipología de taller en la literatura es conocida como *jop-shop*.

Este es, en definitiva, el problema que aborda el trabajo: anticipar la desviación entre lo planificado y lo ejecutado para dar soporte al planificador, aprovechando datos reales que la planta ya genera.

La hipótesis de partida de este trabajo es que los datos históricos de ERP y MES contienen suficiente información para predecir la desviación teórico-real de una fase en una máquina, con una precisión útil para la planificación. Se considerará confirmada si el modelo reduce el error absoluto medio al menos un 20% respecto a la planificación actual del ERP. La literatura revisada no proporciona valores de referencia para este tipo de umbral. El criterio se establece a partir de la valoración del departamento técnico de producción de la fábrica, con el fin de disponer de una referencia fijada antes de obtener los resultados para este prototipo.

Objetivos específicos:

1. Determinar si los datos históricos de ERP y MES contienen información suficiente para predecir la desviación entre el tiempo teórico y el tiempo real de una fase asignada a una máquina.
2. Comparar la capacidad predictiva de distintos enfoques de modelado sobre estos datos, mediante el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE), para determinar cuál anticipa mejor la desviación.

El resultado esperado es un prototipo basado en técnicas de *aprendizaje automático* que demuestre, sobre datos reales, la viabilidad de este enfoque. No se pretende construir un sistema productivo, sino evidenciar el valor que la explotación conjunta de los datos de ERP y MES puede aportar a la mejora de la planificación.

2. Marco teórico

Sistemas ERP y MES

Los sistemas actuales de gestión de la producción son el resultado de una evolución de varias décadas. Su origen se sitúa en los sistemas MRP (*Material Requirements Planning*), surgidos en los años sesenta y setenta para calcular las necesidades de materiales a partir del plan maestro de producción. Posteriormente, el MRP II (*Manufacturing Resource Planning*) incorporó la planificación de capacidad y otros recursos productivos. El paso siguiente fue el ERP, que amplió el alcance más allá de la producción para integrar en un único sistema las distintas áreas de la empresa: compras, ventas, inventarios, finanzas y fabricación [Guo et al. 2022].

Element	ROP	MRP	MRP-II	ERP/MES/APS
Starting point	Early-1960s	Mid-1960s	Mid-1970s	Early-1990s
Market environment	• Demand>Supply • Almost identical products with extremely high-volume	• Demand>Supply • Few products with high-volume production	• Demand>Supply • Narrow product range with high-volume	• Supply>Demand • A larger variety of almost-customized products in large/medium quantities
Primary priority	• Inventory control	• Material requirement planning and inventory control	• Material requirement planning and inventory control	• Resources planning as well as production planning and control
MPC strategy	• Product-focused • Assumption of infinite capacity • Min/max reorder point logic based on historical demand	• Site-centric • Assumption of infinite capacity • Hierarchical planning and control based on future demand	• Site-centric • Considering capacity constraints • Integrated and closed-loop planning and control with forecasted demand	• Supply chain-oriented • Integration of business processes beyond the site and corporate boundaries • Feasible and reasonable planning and control with more realistic constraints
Technology enabler	• Automation	• Automation • Information technology	• Automation • Information technology	• Automation • Information and communications technology • Operations research technique
Interface	• Manual form & correspondences	• Mainframe systems	• Mainframe systems • Mini-computer systems	• Mini-computer systems • Client-server systems • Web-server systems

Ilustración 1: Tabla evolución de los sistemas de gestión industriales [Guo et al. 2022].

Hasta los años noventa estos sistemas compartían una limitación estructural: estaban centrados en la planificación y el control de materiales, y no eran capaces de gestionar en tiempo real lo que ocurría en los procesos de fabricación y en los puestos de producción.

De esa carencia nace el MES, cuyo concepto fue acuñado en 1992 por AMR Research como el nivel de ejecución que conecta las funciones de negocio con los sistemas de control de proceso, aportando visibilidad y control funcional sobre la planta. El MES actúa como puente entre el nivel de gestión y el taller: captura la ejecución a pie de

máquina y devuelve a la planificación una imagen de lo que realmente ha sucedido [Realyvásquez-Vargas & Z-Flores, 2021].

Manufacturing Planning and Control (MPC)

La literatura reciente enmarca esta evolución bajo el concepto MPC (*Manufacturing Planning and Control*), que agrupa el conjunto de sistemas y procesos con los que una empresa planifica y controla su producción. Las propuestas más avanzadas apuntan hacia sistemas orientados a la sincronización en tiempo real entre planificación y ejecución, en línea con los paradigmas de la Industria 4.0 [Guo et al., 2022] y con el concepto de sistemas de fabricación inteligentes (IMS, Intelligent Manufacturing Systems) [Kishorre Annanth et al., 2021]. Las industrias más punteras incorporan ya tecnologías como el IIoT (Industrial Internet of Things), los gemelos digitales (digital twins), el cloud computing o la explotación masiva de datos mediante modelos de inteligencia artificial.

Este esquema general se materializa de forma directa en la planta objeto de estudio. El ERP gestiona el flujo logístico completo, compras, ventas, inventarios, costes y órdenes de producción. Paralelamente el MES recoge datos de planta en tiempo real, lo que permite seguir la evolución de la producción durante su ejecución y, una vez finalizada, disponer de la trazabilidad completa y obtener los tiempos reales imputados a cada orden de trabajo.

La planta de mecanizados que acoge el estudio de este trabajo lleva casi tres años operando con ambos sistemas, lo que presenta una doble lectura para este trabajo. Por un lado, debe existir un historial de datos suficiente para plantear un enfoque basado en *aprendizaje automático*. Por el otro lado, se trata de una implantación relativamente reciente, propia de una empresa en proceso de digitalización y alejada todavía de los escenarios altamente tecnificados que describe la literatura más vanguardista. Este contraste entre el estado del arte tecnológico y la realidad de una planta industrial media es, precisamente, uno de los contextos donde esta investigación cobra sentido: extraer valor de los datos disponibles hoy, sin esperar a infraestructuras futuras.

Planificación y Control de la Producción (PCC)

Los sistemas ERP y MES están orientados a dar soporte a la planificación y control de la producción (PPC, *Production Planning and Control*): el conjunto de procesos que organiza, coordina y supervisa los recursos productivos de una empresa. La PPC comprende cuatro actividades fundamentales: la carga (*loading*) determina cuánto trabajo asignar a cada recurso; la programación (*scheduling*) establece cuándo realizar cada trabajo; la secuenciación (*sequencing*) fija en qué orden ejecutarlos; y la monitorización y control (*monitoring and control*) verifica si las actividades transcurren según el plan trazado y qué acciones correctivas requieren [Oluyisola et al., 2022].

Una línea de producción puede definirse como un proceso de fabricación o ensamblaje en el que los materiales se procesan de forma secuencial: la materia prima atraviesa una serie de estaciones de trabajo hasta convertirse en el producto final [Bierbooms, 2012, citado en Kang et al., 2020]. En el contexto de este trabajo, esa secuencia de estaciones se corresponde con la ruta de fabricación definida en el ERP, donde se especifican las fases por las que debe pasar la materia prima.

Los procesos productivos así entendidos pueden clasificarse en distintas configuraciones: taller (*job-shop*), por lotes, repetitiva, continua y producción en masa. El caso que ocupa a este trabajo se sitúa en la primera de ellas: un taller donde cada operación puede ejecutarse en máquinas alternativas. Este escenario tiene una formulación clásica en la literatura de investigación operativa, el problema de programación de taller flexible o FJSP (*Flexible Job Shop Scheduling Problem*) [Dauzère-Pérès et al., 2024].

En el FJSP se dispone de un conjunto de máquinas y de un conjunto de trabajos, cada uno compuesto por una secuencia de operaciones. Cada operación puede procesarse en cualquier máquina de un subconjunto de máquinas compatibles o elegibles, y su tiempo de proceso depende de la máquina concreta en que se ejecute. Resolver este problema exige tomar dos decisiones entrelazadas: asignar cada operación a una de sus máquinas elegibles y secuenciar las operaciones en cada máquina. El FJSP es un problema de optimización combinatoria NP-hard. Según el trabajo de investigación de *Dauzère-Pérès*, citado en la párrafo anterior, no se conocen algoritmos capaces de resolverlo de forma exacta en tiempo razonable, salvo en instancias pequeñas, por lo que las investigaciones se han volcado en heurísticas y metaheurísticas de muy diversos tipos.

La correspondencia con el caso de estudio es directa. Las fases son las operaciones, los grupos de máquinas definen los conjuntos de elegibilidad, y el hecho de que el tiempo de proceso dependa de la máquina concreta es, precisamente, el fenómeno que se pretende predecir. Sin embargo, como se argumentó en la introducción, este estudio no aborda la resolución del FJSP.

Analítica descriptiva, predictiva y prescriptiva

La analítica de datos suele clasificarse en tres niveles según la pregunta a la que responde. La analítica *descriptiva* examina los datos históricos para explicar *qué ha ocurrido*; la *predictiva* emplea esos mismos datos, junto con métodos estadísticos, para anticipar *qué es probable que ocurra*; y la *prescriptiva* utiliza algoritmos para determinar *qué decisión debería tomarse* para influir en ese futuro probable, recomendando una acción a partir del pronóstico.

Estos tres niveles no son excluyentes, sino escalonados. Cada uno se apoya en el anterior y aumenta tanto el valor potencial de la información como la complejidad de obtenerla. Pasar de predecir a prescribir exige un salto cualitativo, ya no basta con

estimar un resultado, sino que hay que modelar el espacio de decisiones posibles, sus restricciones y un criterio para elegir entre ellas [Roy et al. 2022].

Esta clasificación permite situar con precisión la contribución del presente trabajo. El modelo propuesto opera en el nivel predictivo, estima la desviación esperada entre el tiempo teórico y el real de una fase asignada a una máquina. Deliberadamente, no cruza al nivel prescriptivo, no recomienda en qué máquina ejecutar cada fase, por las razones expuestas en la introducción.

Vista así, la aportación del trabajo puede resumirse en un cambio de nivel. Actualmente los datos de ERP y MES se explotan en la planta únicamente de forma descriptiva, principalmente aportan a la trazabilidad y el control de costes. Este trabajo eleva al nivel predictivo.

Aprendizaje automático para regresión

El *aprendizaje automático* agrupa las técnicas que permiten a un sistema aprender patrones a partir de datos, prescindiendo de programación explícita para cada caso. Dentro de él, el *aprendizaje supervisado* trabaja con ejemplos etiquetados: cada observación incluye unas variables de entrada (*features*) y un valor de salida (*target*) que se desea aprender. Cuando esa salida es una categoría, el problema es de clasificación; cuando es un valor numérico continuo, de regresión. El problema, en el marco de este trabajo, es de regresión. La variable a predecir es la desviación entre el tiempo teórico y el tiempo real de una fase, una magnitud continua.

Existen numerosos algoritmos aplicables a problemas de regresión. Su rendimiento no es uniforme, depende de las características del conjunto de datos, de la estrategia de entrenamiento y del propio modelo, por lo que la elección del algoritmo debe evaluarse de forma empírica para cada caso. La evaluación se realiza sobre datos no vistos durante el entrenamiento, para medir la capacidad de generalización del modelo. El esquema de validación empleado influye de forma notable en los resultados, y la validación cruzada resulta recomendable en estudios de regresión [Sekeroglu et al., 2022].

Para cuantificar el error de predicción se emplean distintas métricas. Las más habituales en la literatura de predicción de tiempos son el *error porcentual absoluto medio* (*MAPE*), presente en cerca de la mitad de los trabajos, la *raíz del error cuadrático medio* (*RMSE*) y el *error absoluto medio* (*MAE*) [Koblasa & Urban, 2026]. Cada una de ellas aporta una perspectiva distinta: el MAPE expresa el error en términos relativos, lo que facilita la comparación entre casos; el RMSE penaliza con mayor fuerza las desviaciones grandes; y el MAE resulta más robusto frente a valores atípicos. La combinación de MAPE y RMSE es la más frecuente, al equilibrar la interpretabilidad del primero con la sensibilidad del segundo a los errores de mayor magnitud, según el estudio anteriormente citado. Las métricas concretas empleadas en este trabajo y el procedimiento de validación se detallan en el apartado de la metodología.

3. Estado del Arte

Enfoques de resolución del FJSP

El FJSP, presentado en el marco teórico, cuenta con una extensa literatura de métodos de resolución. Dauzère-Pérès et al. (2024) los clasifican en tres categorías según el enfoque de resolución: métodos exactos, heurísticos y metaheurísticos.

Dos observaciones de esta revisión interesan a este trabajo más allá de los métodos en sí. La primera se refiere al criterio de optimización. El *makespan* es el más estudiado, pero rara vez resulta relevante en entornos reales, donde deben considerarse múltiples criterios. Esta constatación coincide con la premisa de partida de este trabajo: el tiempo no es la única variable que define una buena asignación entre máquina y fase. La segunda observación afecta a los datos de entrada. Se asumen como conocidos los tiempos reales del proceso, sin contemplar desviaciones en los mismos. Incluso las variantes estocásticas los modelan mediante distribuciones y simulación, sin explotar el histórico real de la planta. Los propios autores señalan como línea pendiente de investigación el caso en que los tiempos de una operación resultan más inciertos en una máquina que en otra para un mismo grupo.

El trabajo de investigación de este proyecto no compite, por tanto, con los métodos de resolución del FJSP. El prototipo propuesto en este trabajo no determina en qué máquina debe ejecutarse cada fase, sino que estima la desviación esperada de una asignación concreta.

Aprendizaje automático en sistemas ERP y MES

La integración del *aprendizaje automático* en los sistemas ERP constituye una línea de avance prioritaria en el entorno empresarial actual [Jawad & Balázs, 2024]. Las aplicaciones recopiladas cubren un espectro amplio: gestión de inventarios, previsión de demanda, programación de la producción, control de calidad, mantenimiento predictivo y gestión de la cadena de suministro.

Entre ellas destaca la *analítica predictiva*, donde los algoritmos analizan datos históricos para anticipar tendencias y patrones de demanda. La elección de la técnica adecuada depende del caso de uso concreto, así como de la calidad y la arquitectura de los datos disponibles [Jawad & Balázs, 2024].

Conviene notar el nivel al que operan estas aplicaciones. Unas se orientan a magnitudes agregadas del negocio, como la demanda, el inventario o la cadena de suministro. Otras emplean el aprendizaje automático como apoyo para resolver la programación de la producción, es decir, para decidir de forma óptima qué trabajos asignar a qué recursos.

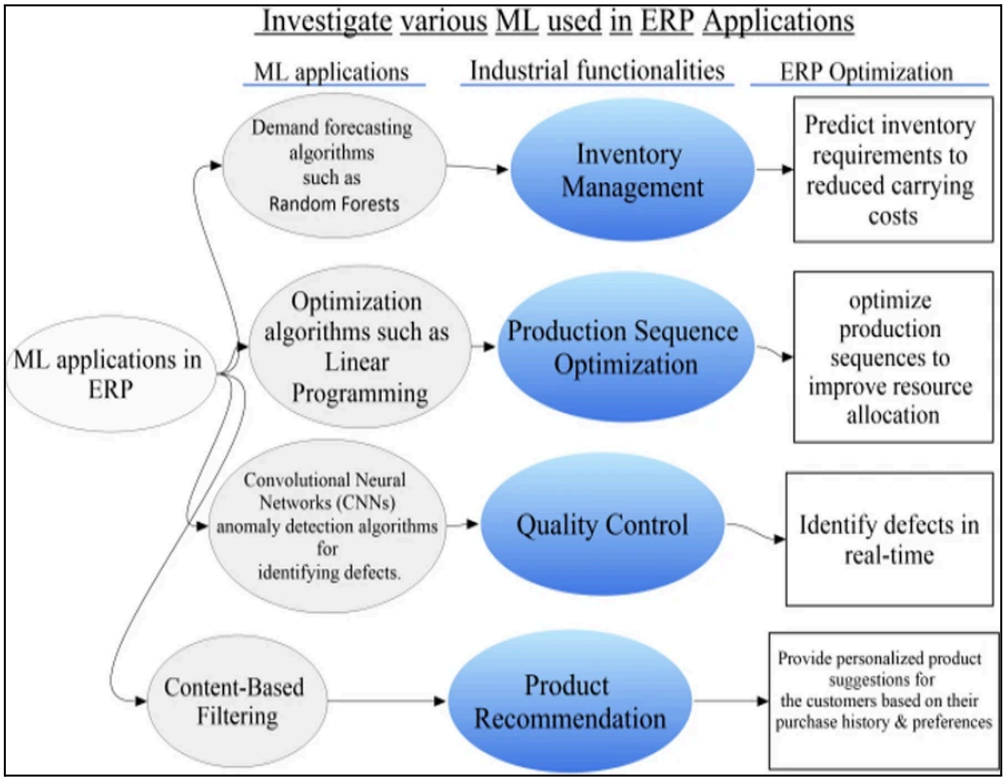


Ilustración 2: Muestra las distintas ramas de ML y su aplicabilidad en ERP [Jawad & Balázs, 2024]

Aprendizaje automático en la planificación y control de la producción (PCC)

En el ámbito específico de la planificación y control de la producción, Oluyisola et al. (2022) recopilan aplicaciones de aprendizaje automático clasificadas por tipo de aprendizaje y nivel de decisión. En los niveles táctico y operativo predominan los enfoques supervisados de regresión, junto a propuestas de aprendizaje por refuerzo para la replanificación en tiempo real. El trabajo aquí propuesto se sitúa en el espacio de *aprendizaje supervisado* en el nivel táctico-operativo.

	Strategic	Tactical	Operational
Supervised [linear and non-linear regression, support vector machine, k-nearest neighbors, linear discriminant analysis]	Predicting production costs for different scenarios—dedicated vs. reconfigurable production lines (1) – *Random forests*	Predicting capacity requirements (2) – *Multivariate linear regression*	Dynamic selection of suitable dispatching rule (3)—*Gaussian process regression*
Unsupervised [principal component analysis (PCA), k-means, self-organizing map]	Vendor selection (4) – *PCA*; Strategic sourcing (5) – *k-means*	Prediction of future production bottlenecks (6) – *Levenberg–Marquardt*;	Real-time shop floor control and selection of scheduling rules (7) – *Self-organizing map*
Reinforcement [Q-learning, Monte Carlo, SARSA, Relational]	Joint pricing and lead-time decisions (8) – *Q-learning*	Line balancing/ resource levelling under uncertain demand (9) – *Monte Carlo*	Adaptive multi-agent scheduling in multi-site production (10) – *SARSA*; and Real-time rescheduling (11) – *Relational RL*

Ilustración 3: Muestra las distintas ramas del ML y su enfoque en entornos PCC

Asimismo, una buena perspectiva sistemática la aporta la revisión de Kang et al. (2020), en la que se analizan 39 estudios sobre la aplicación de aprendizaje automático en líneas de producción. Sus resultados describen un campo dominado por el *aprendizaje supervisado* y, en particular, por la soluciones de tipo regresión, presente en torno al 60% de los trabajos. La predicción de la calidad y del tiempo de ciclo constituyen los problemas más recurrentes.

Sin embargo, definen dos líneas relevantes pendientes de investigación. La primera es la necesidad de modelos para estaciones con múltiples máquinas equivalentes, el caso que aborda este trabajo, frente al escenario de máquina única que predomina en la literatura. La segunda es la disponibilidad y la calidad de los datos como condicionante del rendimiento de los modelos.

Predicción de tiempos de producción

La predicción de la duración de los procesos productivos constituye un requisito creciente de los sistemas de fabricación modernos. De ella dependen la planificación, la estimación de costes y la asignación de capacidad [Matějka et al. 2026]. En la práctica, sin embargo, los tiempos de producción suelen tratarse como valores fijos o como medias derivadas del histórico. Esta simplificación conduce a planes mal alineados con la realidad y a desviaciones durante la ejecución [Koblasa & Urban, 2026].

La literatura distingue principalmente dos magnitudes. El tiempo de ciclo (*CT*): periodo que una orden o proceso requiere en un puesto de trabajo. El lead time (*LT*): periodo que abarca desde el inicio de la primera actividad hasta el fin de la última, e incluye tiempos de calidad, logística y espera en cola [Bokranz et al., 2006, citado en Koblasa & Urban, 2026]. La variable de este trabajo es el tiempo efectivo de una fase en una máquina, con preparación y producción incluidas. Se corresponde, por tanto, con la primera magnitud (*CT*): un tiempo de ciclo a nivel de fase, sin componentes logísticos ni de espera.

Un *scoping review* de 173 trabajos publicados entre 2000 y 2024 ofrece el mapa de este subcampo [Koblasa & Urban, 2026]. La predicción de ambas magnitudes se apoya mayoritariamente en datos históricos, y los sistemas ERP y MES son la fuente más utilizada. En la misma línea, Matějka et al. (2026) observan que los modelos que aprenden de los datos se adaptan mejor que las fórmulas fijas cuando la variedad de trabajos es alta. Esta situación es característica en las tipologías de fabricación bajo pedido, conocidas como *make-to-order*.

El *scoping review* señala además carencias metodológicas persistentes: definiciones inconsistentes de los tiempos, métricas y procedimientos de validación dispares y una atención limitada a la credibilidad de los datos y a la integración entre sistemas. Sus autores advierten que los registros históricos presentan inconsistencias características,

como marcas de tiempo no estandarizadas, variaciones del flujo no recogidas en las variables y distorsiones de origen humano [Koblasa & Urban, 2026].

Buena parte de los trabajos de este subcampo se apoyan en simulación. Can y Heavey (2016) emplean programación genética para predecir el tiempo de ciclo de una línea de producción entera, no de una máquina con una fase. La aproximación se construye y valida sobre un modelo de simulación de eventos discretos, no sobre el histórico real de una planta. Sus autores proponen como mejora futura aumentar la granularidad, llevando el cálculo del nivel de sistema al de estación individual.

La predicción sobre datos reales de plantas resulta minoritaria, pero está presente en la literatura. Hay casos donde se proponen modelos predictivos del tiempo de ciclo restante sobre registros reales de fabricación, mediante una combinación de minería de procesos y regresión estadística [Choueiri et al. 2020, citado en Koblasa & Urban, 2026]. En entornos de taller, Ghasemi et al. (2022) entrenan un modelo predictivo con datos históricos de un sistema MES, aunque su objetivo final es la programación de la producción y no la predicción en sí misma. Matějka et al. (2026) recogen asimismo trabajo empírico que confirma la mejora significativa que aportan modelos relativamente simples, como *random forest*, *gradient boosting* o *support vector machine*, cuando se acompañan de variables bien diseñadas. La misma revisión describe esta vía como pragmática, mejores estimaciones sin exigir grandes volúmenes de datos ni sustituir los sistemas existentes.

El espacio que ocupa este trabajo

La literatura revisada dibuja un panorama definido. La predicción de tiempos de producción constituye un subcampo activo y en crecimiento, apoyado mayoritariamente en datos históricos de sistemas ERP y MES. El *aprendizaje automático* gana terreno frente a los enfoques deterministas allí donde la variabilidad del proceso es alta. Los métodos, las fuentes y las técnicas que este trabajo emplea se sitúan, por tanto, en la corriente principal del campo.

Esta revisión se ha realizado sobre las bases de datos Scopus y Web of Science, complementadas con búsquedas en Google Scholar y con el seguimiento de las referencias y citas de los trabajos más próximos. Además de información en portales web y convenciones. Se han empleado combinaciones de los términos *cycle time prediction*, *processing time prediction*, *lead time prediction*, *machine learning*, *manufacturing*, *MES*, *ERP*, *job shop* y *deviation planned actual time*, en inglés, con especial enfoque en publicaciones comprendidas entre 2020 y 2026.

Dentro de ese alcance no se ha identificado ningún trabajo que prediga la desviación entre el tiempo teórico planificado y el tiempo real de ejecución, a nivel de fase individual en una máquina concreta, dentro de grupos de máquinas alternativas y a partir de datos integrados entre ERP y MES en una planta real. Cada componente de esta intersección cuenta con literatura propia. Su combinación, no.

Esta ausencia no parece casual, y la propia literatura apunta sus causas. Por un lado, la investigación trabaja con los datos a los que puede acceder: simulaciones, bancos de prueba o sectores altamente automatizados. El scoping review de Koblasa y Urban (2026) señala expresamente la escasez de aplicaciones prácticas fuera de sectores como el semiconductor o la automoción. Los datos integrados de ERP y MES de una planta industrial media constituyen, en cambio, un activo privado rara vez accesible para el investigador. Por otro lado, la desviación frente a lo planificado sólo emerge como variable de interés cuando existe un plan que corregir. Se trata de una formulación que nace de la práctica industrial más que del entorno académico. A ello se suma una diferencia de partida en la propia naturaleza de los datos. Buena parte de los trabajos revisados opera con información detallada del estado de las máquinas, obtenida mediante sensórica e IoT, o con descripciones extensas de las características del artículo a fabricar (BOM). Este trabajo no dispone de ninguna de las dos fuentes, se limita a la información que los sistemas ERP y MES ya registran por su funcionamiento ordinario. Esta restricción define el alcance del prototipo, pero también su interés práctico, al reproducir las condiciones reales de una planta sin instrumentación adicional.

Las direcciones futuras señaladas por la literatura convergen sobre este mismo espacio. La incertidumbre del tiempo de proceso según la máquina asignada [Dauzère-Pérès et al., 2024], el cálculo de las métricas a nivel de cada máquina en lugar del conjunto del sistema completo [Can & Heavey, 2016], la necesidad de modelos para estaciones con múltiples máquinas equivalentes [Kang et al., 2020] y la atención a la credibilidad de los datos y a la integración entre sistemas [Koblasa & Urban, 2026]. Todo esto, en conjunto, describe el espacio de este trabajo. La literatura reciente define esta vía como pragmática: permite obtener mejores estimaciones sin exigir grandes volúmenes de datos ni sustituir los sistemas existentes, partiendo de una recogida disciplinada de datos, un conjunto reducido pero bien elegido de variables y algoritmos [Matějka et al., 2026].

4. Metodología

Se adopta CRISP-DM (*Cross-Industry Standard Process for Data Mining*) por su carácter consolidado [Chapman et al., 1999]. Existen adaptaciones recientes orientadas al *aprendizaje automático*, como CRISP-ML(Q) [Studer et al., 2021], que incorporan control de la calidad y el mantenimiento del modelo en producción. Dado que este trabajo se plantea como prototipo, sin fase de explotación, se emplea el marco original.

La metodología CRISP-DM define una serie de fases, cada una con tareas concretas. El presente trabajo adopta sus seis fases como estructura de desarrollo. Las tareas de cada fase, en cambio, se adaptan al contexto y al alcance del proyecto, tal como la propia metodología contempla.

4.1 Comprensión del negocio

4.1.1 Contexto del negocio

La implementación se desarrolla en una fábrica de mecanizados industriales. La empresa transforma el metal mediante distintos procesos para conferir una forma y unas propiedades concretas. Las piezas resultantes son, en su mayoría, componentes o ensambles para maquinaria, vehículos y construcción. El modo de producción es *make-to-order*. Su variabilidad de productos tiene un límite físico, el conjunto de máquinas disponibles. No puede asumir diseños que sus equipos no sean capaces de procesar. Por ello, la totalidad de los trabajos posibles está definida de antemano. Cada fase se corresponde con un tipo de trabajo concreto. La línea de producción se organiza como un taller, o *job-shop*: distintos grupos de máquinas pueden realizar distintos trabajos (fases) concretos.

La empresa pone a disposición del estudio sus bases de datos, tanto de ERP como de MES, con el fin de llevar a cabo el prototipo. Además facilita la comunicación con su equipo de ingenieros de producción (oficina técnica) para tomar decisiones conjuntas en el transcurso del proyecto.

4.1.2 Definición del problema

Definición problema del negocio

La empresa plantea su necesidad en términos prácticos, disponer de una solución de inteligencia artificial que determine la asignación más adecuada entre fase y máquina. Esa formulación corresponde al nivel prescriptivo de la analítica de datos, cuyas limitaciones en este contexto se han expuesto con anterioridad. El trabajo adopta, por ello, un planteamiento abordable con los datos disponibles.

El análisis del funcionamiento de la planta permite acotar el problema. La producción se planifica con los tiempos teóricos que aporta el ERP, mientras que la ejecución real

queda registrada en el MES. Entre ambos valores surge una discrepancia sistemática, el tiempo invertido rara vez coincide con el previsto. Esta diferencia no constituye un hecho aislado. Introduce incertidumbre en la planificación y en la estimación de costes durante la elaboración de presupuestos. El taller opera, en consecuencia, con tiempos estáticos que no recogen la variabilidad real de la fabricación.

La dificultad se concentra en el reparto de fases entre máquinas de un mismo grupo. Una misma operación puede ejecutarse en varios equipos, con resultados distintos. Gracias al MES la planta ya genera los datos que describen este comportamiento. Sin embargo, los aprovecha solo de forma descriptiva, con fines de trazabilidad y control de costes. Su valor para anticipar la desviación permanece sin explotar.

En consecuencia, este estudio no determina en qué máquina debe ejecutarse cada fase. Actúa un paso antes. Dada una asignación concreta, estima la desviación que cabe esperar entre el tiempo teórico y el real. Como se expuso en el marco teórico, el planteamiento se sitúa así en el nivel predictivo de la analítica de datos, y no en el prescriptivo. La elección final permanece en manos del usuario que planifique o estime el presupuesto.

Definición del problema analítico

Definido de este modo, el problema pertenece al *aprendizaje supervisado*, en su variante de regresión. La revisión del estado del arte respalda esta elección, la regresión supervisada es el enfoque predominante en la predicción de tiempos sobre líneas de producción [Kang et al., 2020]. La entrada del modelo son las variables (*features*) que describen la asignación de una fase a una máquina. La salida es un valor numérico continuo, la desviación esperada. Esta es la desviación relativa entre el tiempo previsto de una fase y su tiempo real de ejecución. Se expresa como un cociente entre ambos tiempos, y no como una diferencia absoluta:

$$ratio \;=\; tiempo\ real\ efectivo \;/\; tiempo\ teórico\ previsto$$

El uso de un cociente responde a una razón concreta. Una diferencia absoluta depende de la duración de la fase. Una discrepancia de diez minutos no representa lo mismo en una operación de quince minutos que en una de ocho horas. El cociente, en cambio, es independiente de la escala. Permite comparar en los mismos términos fases de duración distinta. La lectura del ratio es directa. Un valor próximo a uno indica que la ejecución se ajusta a lo previsto, esto es, una asignación acertada. Un valor superior a uno señala que el tiempo real ha superado la estimación. Un valor inferior refleja lo contrario. Cada término del cociente procede de un sistema distinto. El tiempo teórico previsto lo aporta el ERP. Es la suma del tiempo de preparación y del tiempo de ejecución definidos para la fase. El tiempo real efectivo procede del MES. Se corresponde con el tiempo de ciclo de la fase, obtenido tras agregar todas sus

imputaciones y aplicar la corrección por dedicación. El procedimiento concreto de cálculo se detalla en la preparación de los datos.

La unidad de análisis de este trabajo es la fase de producción. La elección no es arbitraria. La fase es el punto donde se encuentran los dos sistemas: el ERP la planifica con un tiempo teórico y el MES registra su tiempo de ejecución. Los tiempos tanto del ERP como del MES siempre se trabajarán en minutos.

El estudio no abarca todas las fases de la planta. Su alcance se acota mediante dos criterios.

1. *Existencia de una elección real de máquina*: solo se consideran las fases que pueden ejecutarse en grupos de máquinas intercambiables. Cuando una familia dispone de una sola máquina, no hay asignación que decidir y, por tanto, apenas hay incertidumbre en la planificación.
2. *Naturaleza del proceso de fabricación*: se seleccionan las familias de mecanizado. Según el equipo de producción de la planta, en estos procesos la máquina constituye un factor determinante del tiempo de ejecución. Esta característica hace que anticipar la desviación resulte especialmente informativa en dichas familias.

Toda máquina que cumple este doble criterio se considera como *máquina de mecanizado productiva*.

La fábrica cuenta con nueve familias de máquinas que ofrecen esa capacidad de elección real, todas las demás familias han sido descartadas por los criterios antes descritos. Este recorte es una decisión deliberada, no una carencia. Concentra el trabajo en el escenario donde la predicción aporta valor, la asignación entre equipos equivalentes. Este estudio no exige información sensórica adicional ni descripciones detalladas del producto. Emplea únicamente la información que el ERP y el MES ya registran.

4.1.3 Supuestos, restricciones y riesgos

El resultado de este trabajo es un prototipo. No constituye un sistema en producción. Su finalidad es demostrar la viabilidad del enfoque sobre datos reales. No pretende sustituir las herramientas de planificación de la planta.

El estudio parte de varios supuestos, vinculados a los objetivos del proyecto.

El primero se refiere al grado de digitalización de la planta. El ERP y el MES se implantaron a finales de 2024, en el marco de un proceso de transformación digital todavía en curso. El escenario se aleja de las plantas altamente tecnificadas que describe la literatura más avanzada, por lo que el trabajo asume condiciones de digitalización media.

El segundo se refiere al volumen de datos disponible. La implantación del MES fue posterior a la del ERP, por lo que su histórico de registros es más corto. A esto se añade que los seis primeros meses de funcionamiento se consideran inestables. La puesta en marcha fue progresiva y generó un volumen elevado de registros erróneos, muchos de ellos imposibles de detectar sin una inspección individual. El intervalo de datos válidos queda así reducido a catorce meses. El supuesto asume que este periodo resulta suficiente para plantear un enfoque basado en *aprendizaje automático*.

Existen riesgos ligados a la calidad del dato. Distintos autores advierten de inconsistencias habituales en los registros históricos [Koblasa & Urban, 2026]. Para el caso de estudio el principal problema detectado es el factor humano, especialmente en el MES. Las imputaciones en MES se realizan de forma manual, pudiendo incurrir en diversos errores. Estos riesgos condicionan el trabajo. Su tratamiento se aborda en la preparación de los datos.

El contexto productivo refuerza el interés del enfoque. La planta (*job-shop*) fabrica bajo pedido (*make-to-order*), con alta variedad de trabajos. En ese modo de producción, anticipar la duración de las operaciones es una tarea de gestión especialmente relevante [Matějka et al., 2026].

4.2 Comprensión de los datos

4.2.1 Estructura de la información en ERP y MES

Para contextualizar este trabajo es necesario detallar qué información contiene cada sistema y cómo se relaciona entre sí. Tanto los sistemas ERP como los MES son productos de software industrial, construidos sobre bases de datos relacionales.

En el marco del ERP, el eje central son los artículos. Un *artículo* es cualquier producto, servicio o elemento con el que opera una empresa y que requiere control, seguimiento o gestión en sus procesos. En el caso que abarca este proyecto, los artículos relevantes son los relacionados con la fabricación: el producto a fabricar. El artículo a fabricar se especifica en una *orden de fabricación*.

Esta orden de fabricación define qué artículo fabricar y en qué cantidad. Cada orden lleva asociada una *ruta de fabricación*: la secuencia ordenada de *fases* u operaciones necesarias para completar el producto, junto con el recurso o grupo de máquinas previsto para cada una. Cada fase tiene definidos unos *tiempos teóricos* estándar, habitualmente descompuestos en dos componentes: el *tiempo de preparación*, que recoge el acondicionamiento de la máquina antes de producir, y el *tiempo de ejecución*, que abarca el tiempo destinado a producir la operación específica del trabajo. La suma de ambos constituye el tiempo teórico total de la fase, que es la referencia sobre la que el ERP planifica la fecha de finalización y calcula los costes previstos.

En el lado del MES, la unidad básica de registro es la *imputación*: el registro del trabajo realizado por un operario sobre una fase determinada y en una máquina concreta, durante un intervalo de tiempo. Dado que una misma fase puede acumular múltiples imputaciones —de distintos operarios, en distintos turnos o incluso en distintas máquinas—, el tiempo real de dicha fase se obtiene agregando todas sus imputaciones. Es importante resaltar que el tiempo registrado en una imputación es *tiempo de reloj*, el intervalo transcurrido entre el inicio y el fin de la actividad. En entornos donde un operario atiende varias máquinas simultáneamente, ese tiempo de reloj no equivale al tiempo realmente dedicado a cada fase. Para resolverlo, el sistema MES incorpora un *porcentaje de dedicación* que reparte el tiempo del operario entre los trabajos simultáneos. Esto permite calcular el *tiempo efectivo*: la fracción del tiempo de reloj verdaderamente atribuible a cada fase. La distinción entre ambos es crítica para cualquier explotación analítica de datos MES, pues comparar tiempos de reloj con tiempos teóricos conduciría a desviaciones artificialmente infladas.

El punto de unión entre ambos sistemas es la fase: planificada en el ERP con su tiempo teórico, y ejecutada y registrada con tiempos reales en el MES a través de sus imputaciones. Esta correspondencia es la que permite confrontar, para cada fase, lo previsto con lo realmente ocurrido y, por tanto, cuantificar la desviación que es el objeto de este trabajo.

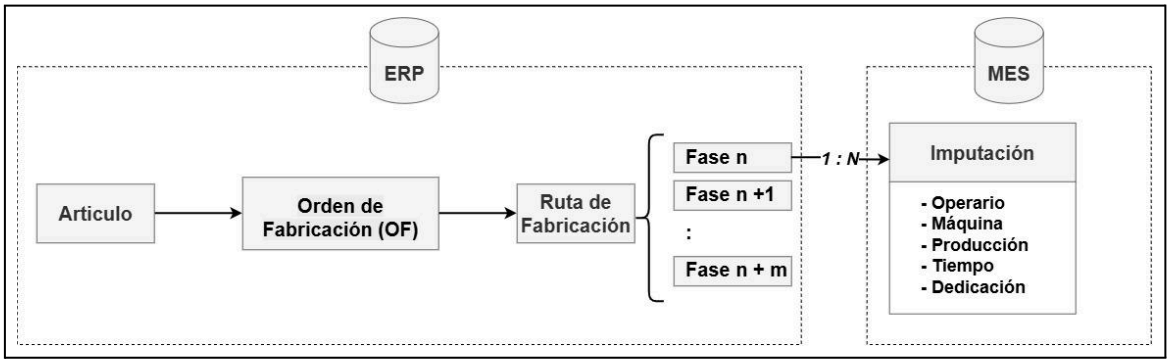


Ilustración 4: Dibujo del flujo digital de fabricación de las distintas entidades a relacionarse entre ERP y MES.

En el “mundo teórico”, el ERP aporta el contexto de la fase (producto, cantidad, tipo de operación, recurso previsto). En el “mundo real”, el MES aporta el detalle de la ejecución (máquina concreta, tiempos, dedicación). La riqueza de esta confrontación depende directamente de la calidad y coherencia con que ambos sistemas registran la información.

4.2.2 Origen y recopilación de los datos

Los datos proceden de los dos sistemas, el ERP y el MES. Cada uno opera sobre su propia base de datos, alojada en un servidor distinto. Ambas se construyen sobre una arquitectura relacional accesible mediante SQL. Esta estructura permite extraer la información almacenada en sus tablas para su posterior análisis.

La correspondencia entre ambos sistemas reside en el MES. Este incorpora una tabla intermedia de mapeo que asocia el identificador único de cada entidad del ERP con su identificador equivalente en el MES. Ese enlace es el que permite confrontar lo planificado en el ERP con lo ejecutado y registrado en el MES.

Ambos sistemas se comunican entre sí en la operación diaria de la planta mediante una interfaz de programación de aplicaciones (API). A través de ella, el ERP transfiere al MES las fases planificadas, y el MES devuelve al ERP las imputaciones registradas. Gracias a ella, los datos de ambos sistemas resultan enlazables para su explotación analítica.

No obstante, esta comunicación tiene un límite relevante para el estudio. El MES recoge los tiempos en las imputaciones. Estos tiempos se almacenan en distintas tablas conteniendo, cada una con información concreta de la imputación. El tiempo real de ejecución no reside, por tanto, en el ERP de forma extraíble directamente. Es necesario realizar un consulta SQL al MES, donde converjan las distintas tablas para extraer el registro completo de las imputaciones.

Para el estudio, la información se extrae de ambas bases mediante consultas SQL directas y se exporta a ficheros CSV. Posteriormente, estos ficheros se unifican en un entorno Python. El detalle de esa unificación se aborda en la preparación de los datos.

4.2.3 Descripción de los datos

La empresa cuenta con más de una planta, el trabajo se centra en la planta dedicada al mecanizado. Se detectan nombres de maquinaria, fases o artículos en catalán.

La información se reparte en once tablas: nueve procedentes del ERP y tres del MES. Cada entidad cuenta con dos identificadores: *id* y *GUID*. El código (*id*) es un identificador único para la entidad en cada tabla y visible a nivel de usuario. El GUID es un identificador único y global que la base de datos asigna a cada instancia, sin presencia en la operativa a nivel usuario. El enlace entre tablas de los distintos sistemas se realiza sobre el GUID y con la tabla intermedia de mapeo. De todas las tablas, las imputaciones son la excepción que no siguen este comportamiento. Las imputaciones se extraen mediante una query cruzando distintos registros, no tiene ningún código que las identifique de forma única. No obstante, tiene un atributo, el GUID de la fase a la que pertenecen, esto sirve para identificarlas.

Una particularidad es destacable y facilita el trabajo, ciertas entidades son enlazables entre tablas de los distintos sistemas mediante el código (*id*), ya que comparten el mismo. En estos casos se permite enlazar tablas de forma más directa que con GUID.

Sistema	Tabla	Información que contiene
ERP	Grupos de máquinas	Grupos / familias de máquinas existentes
ERP	Máquinas	Máquinas y puestos de trabajo
ERP	Relación máquinas–grupos	Asignación de cada máquina a su grupo
ERP	Órdenes de fabricación	Órdenes fabricación para cada artículo
ERP	Fases de fabricación	Fases de cada orden (tiempo teórico)
ERP	Artículos	Artículos con los que trabaja la empresa
ERP	Líneas de Artículos	Líneas a las que pertenecen los artículos.
ERP	Famílias de Artículos	Familias dentro de las líneas.
MES	Imputaciones	Registros del trabajo imputados a cada fase
MES	Nodos	Máquinas y puestos de trabajo en el MES
MES	Mapeo	Relación de GUID entre ERP y MES

Ilustración 5: Descripción de las tablas de datos tomadas en el estudio.

4.2.4 Exploración Inicial

El conjunto extraído abarca desde diciembre de 2024 hasta agosto de 2026. Su volumen de instancias antes de la limpieza es el siguiente:

Sistema	Tabla	Instancias
MES	Imputaciones	196.576
ERP	Fases de fabricación	116.055
ERP	Órdenes de fabricación	18.106

Ilustración 6: Número de instancias por tabla.

Del total de fases registradas en el ERP, no todas cuentan con imputaciones asociadas en el MES. Además existen fases externas, correspondientes a operaciones subcontratadas fuera de la planta de estudio.

Para las tablas que representan las máquinas, ERP registra 120 máquinas y MES 119, distribuidas en 57 famílias. La asignación entre máquinas y grupos se recoge en 115 registros. Esa cifra no coincide con el número de máquinas, esto supone una asignación no unívoca entre máquinas y grupos.

Sistema	Tabla	Instancias
ERP	Grupos de máquinas	57
ERP	Máquinas	120
ERP	Relación máquinas–grupos	115
MES	Nodos	119

Ilustración 7: Número de instancias por tablas

El sistema permite capturar tiempo de forma intermitente. Es decir, en distintos momentos o días pueden hacerse registros de tiempo para una misma fase. Además una misma fase puede tener imputaciones repartidas en distintas máquinas. Entonces una misma fase puede registrar trabajos en más de una máquina, por lo que la imputación es la unidad que refleja la carga real de cada grupo. En última instancia para entrenar el modelo se precisará trabajar a nivel de fases, no de imputaciones.

Este caso concreto, una fase con imputaciones en diversas máquinas, requiere ser inspeccionado. Se inspecciona el total de fases para averiguar el comportamiento con esta casuística:

Número de máquinas	Peso de fases
1	92,84%
2	6,76%
3, 4, 5, 6	> 1%

Ilustración 8: Fases según el número de máquinas en que se imputaron

Del total de fases imputadas el 92.84% se ha imputado en una única máquina, el 6.76% en 2, y menos del 1% en tres, cuatro, cinco o seis máquinas.

Este fenómeno, pese a ser minoritario, debe tenerse en cuenta. Cada fase requiere una única máquina, pero al trabajar con grupos de máquinas equivalentes una misma fase puede ejecutarse en cualquiera de las máquinas de su familia. Los casos registrados responden a cambios de máquina motivados por la disponibilidad. Cuando la producción de una fase no se completa de forma continua, el trabajo puede repartirse en distintos momentos y en distintas máquinas según cuál esté libre. Las incidencias y las averías mecánicas provocan también el traslado del trabajo de una máquina a otra.

La máquina en la que se ha ejecutado una fase se identifica a partir de las imputaciones del MES. La premisa de este trabajo parte de una relación unívoca entre

fase y máquina, esta circunstancia la pone en cuestión. Cuando el trabajo se reparte en distintas máquinas, una misma fase queda asociada a varios equipos. Asignar una única máquina de referencia supone, por tanto, una simplificación. Todo el tiempo de la fase queda atribuido a un solo equipo, aunque parte de él se haya consumido en otro. El criterio adoptado para resolverlo se detalla en el apartado de preparación de los datos.

Antes de filtrar las máquinas bajo el criterio de *máquina de mecanizado productiva*. Se inspecciona la carga de imputaciones para cada grupo de máquinas. Este reparto se presenta en número de imputaciones y no de fases.

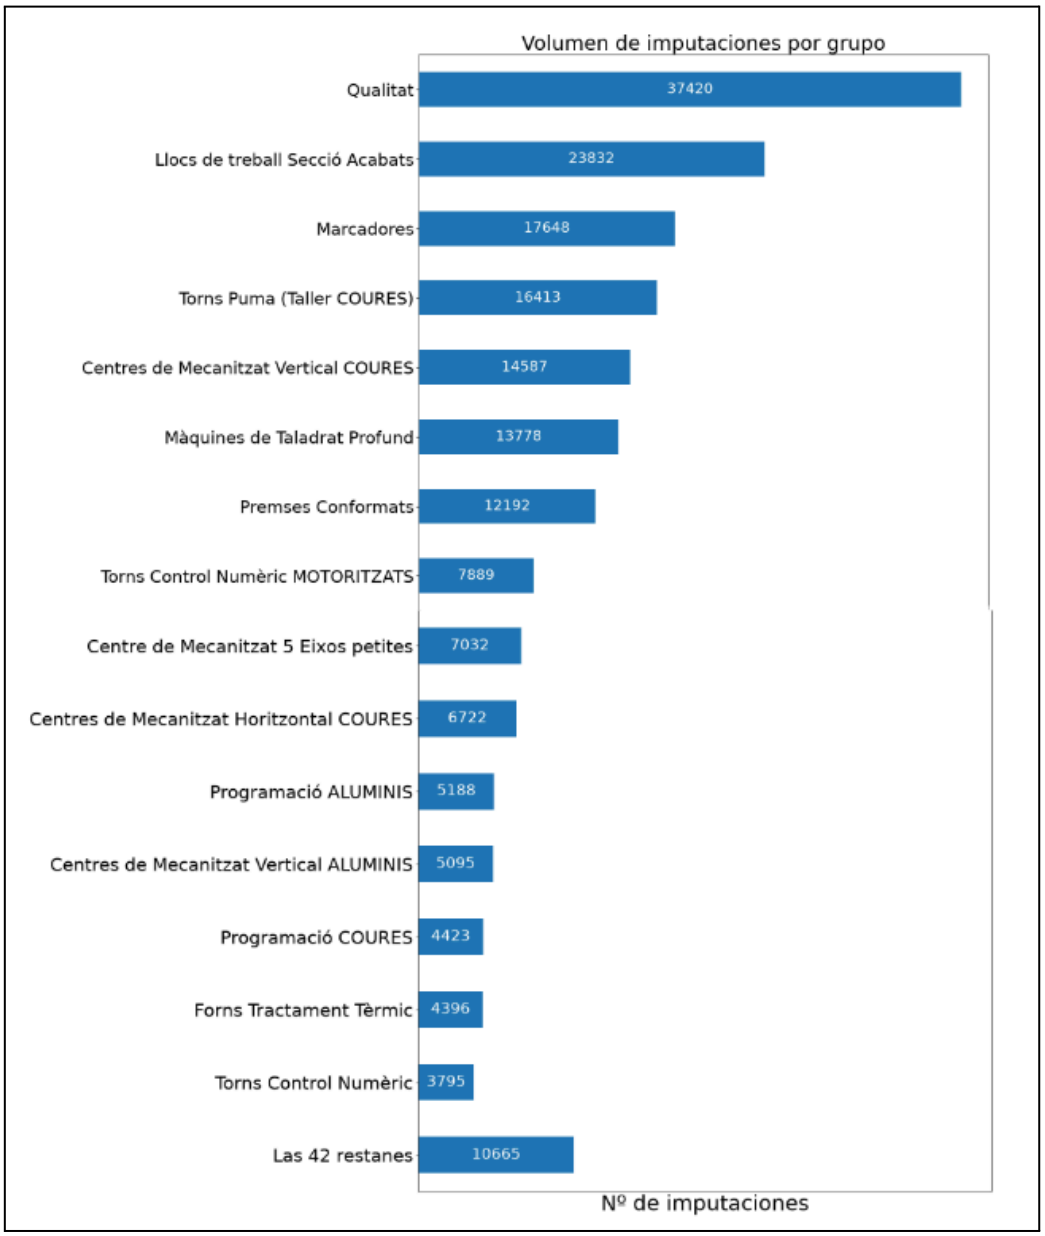


Ilustración 9: Distribución de las imputaciones en los grupos de máquinas originales

La distribución muestra una acumulación destacada en el grupo "Qualitat". El resultado es coherente con su función. Se trata de la estación dedicada a la inspección de calidad, por la que pasan la mayoría de las fases una vez finalizadas. No constituye, sin embargo, un grupo de máquinas en el sentido productivo. La misma circunstancia afecta a otros grupos con elevada carga, como “Marcadors”, el segundo más numeroso, o “Programació”. Estos casos se abordarán con detalle más adelante.

Inspeccionando la cola de familias los números de imputaciones són mucho más reducidos:

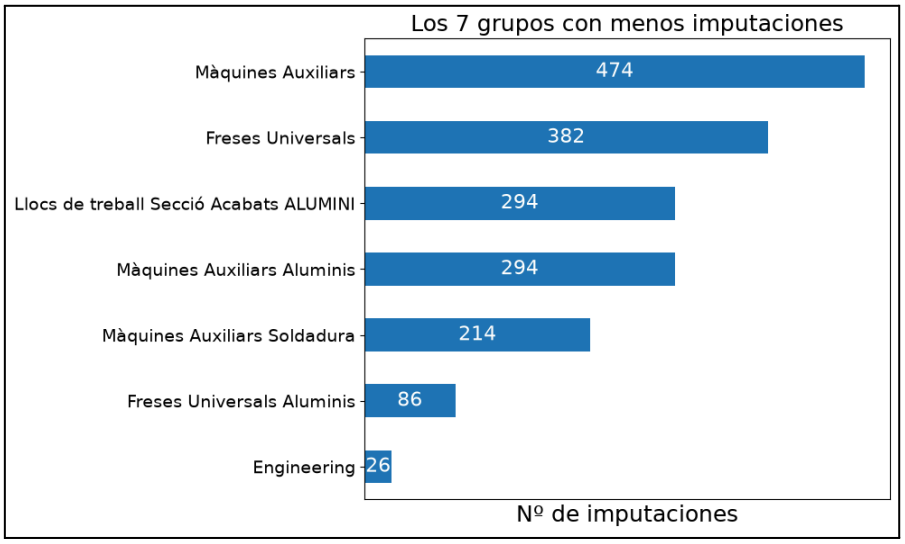


Ilustración 10: Los 7 grupos de máquinas con menos imputaciones

Resultan llamativas las escasas imputaciones que acumulan familias como “Engineering”, o “Freses Universals Alumini”. Su volumen contrasta con el del resto de familias. En última instancia no todas estas máquinas superaran el corte de *máquina de mecanizado productiva*.

Para los artículos, los únicos con los que trabajaremos son aquellos que la empresa fábrica, la producción. El filtrado y limpieza se dará al tener el dataset final, ya que cada OF especifica el artículo a producir, y cada fase cruzará esa información con su OF, por lo tanto no será necesario limpiar esta tablas, con en *join* a las imputaciones finales será suficiente para contar solo con las instancias que pertenezcan al estudio.

Sistema	**Tabla**	**Instancias**
ERP	Artículos	50.312
ERP	Familias de Artículos	18
ERP	Líneas de Artículos	76

Ilustración 11: Tabla de artículos

4.2.5 Verificación de la calidad de los datos

Cerrando la inspección de los datos, esta revela incidencias que condicionan su uso posterior. La presencia de inconsistencias en los registros históricos de sistemas ERP y MES es un fenómeno documentado en la literatura [Koblasa & Urban, 2026]. En su mayoría los errores se deben al factor humano.

En las imputaciones del MES se ha mostrado una gran cantidad de registros asociados a máquinas no productivas, ajenas al ámbito del estudio. Se han detectado ocasiones dónde la misma fase aparece imputada en más de una máquina. Una breve inspección visual a observan tiempos anormalmente elevados, atribuibles, a la vista de su magnitud, a errores en el registro manual por parte de los operarios. Las incidencias surgidas durante la producción se han registrado como imputaciones independientes, al margen del tiempo en máquina. Esto permite tomar el tiempo bruto en máquina directamente como tiempo productivo bruto, sin necesidad de descontar el tiempo de incidencia. Existen fases con tiempo en unidades distintas al minuto.

Debido a diferentes motivos existen órdenes y fases de fabricación que carecen de imputaciones asociadas. Estas se descartan al no tener registros de tiempo con los que realizar el estudio.

En las máquinas y sus grupos aparecen diversas inconsistencias. Existe una máquina registrada en el ERP sin equivalente en el MES. Algunas máquinas figuran asignadas a más de un grupo, y otras carecen de grupo. Ciertos grupos concentran un número muy reducido de imputaciones. Por último, algunos grupos no ofrecen capacidad de elección, al disponer de una sola máquina o al concentrar todo el trabajo en un único equipo. Esto se estudiará siguiendo el criterio esmentado.

4.3 Preparación de los datos

Esta fase persigue un doble objetivo. El primero es acotar el conjunto a la población de estudio. El segundo es garantizar que los tiempos empleados reflejen trabajo real, descartando los registros erróneos del MES. Esta fase aborda el tratamiento de los problemas detectados en la anterior.

4.3.1 Selección de datos

Atributos: De las tablas extraídas se conserva únicamente el subconjunto de campos relevantes. Los sistemas ERP y MES almacenan numerosos atributos ligados a su operativa interna, sin valor para el análisis de la desviación. Se retienen los identificadores necesarios para el enlace entre tablas, los tiempos teóricos y reales, y los campos que describen la fase, la orden, la máquina y el artículo.

Planta: La empresa cuenta con más de una planta de producción. Se descartan los registros ajenos a la planta objeto del estudio, identificada en los sistemas con el código 100. Parte de las tablas ya se han extraído directamente de la base de datos filtrando por este código. El resto se filtró posteriormente en el entorno Python. En

consecuencia, todas las cifras y volúmenes de datos que se presentan –y que se han presentado– en este trabajo corresponden exclusivamente a la planta 100.

Intervalo temporal: Quedan excluidos los registros anteriores al 1 de junio de 2025. Durante los primeros meses de operación, el uso de ambos sistemas no estaba consolidado, lo que eleva la probabilidad de encontrar registros erróneos. Se descartan igualmente los registros posteriores al 1 de agosto de 2026, por corresponder al límite de la extracción. Las órdenes de fabricación se filtran por su fecha de finalización. En una orden no finalizada dentro del intervalo no puede garantizarse que sus imputaciones estén completas, de modo que el tiempo real registrado no refleja el trabajo total de la fase.

Tabla	**Instancias**
Imputaciones iniciales	196.576
Imputaciones en el intervalo temporal	140.485
Fases iniciales	116.055
Fases en el intervalo temporal	69.986
OF iniciales	18.106
OF en el intervalo temporal	11.983

Ilustración 12: Tabla del reparto de instancias entre las tablas en el intervalo de estudio

Órdenes de fabricación: Se eliminan las órdenes en estado de creación. En ese estado el MES no admite imputaciones.

Fases: Se descartan las fases externas, correspondientes a trabajos subcontratados. Así mismo también se excluyen todas las fases sin tiempo teórico definido o fases de OF ya desechadas. Se revisan fases con tiempos teóricos expresados en unidades distintas al minuto. Revisando con el equipo en planta se averigua que el error está en la unidad, no en el valor numérico. Por lo tanto no es necesario convertir a minutos esos tiempos.

Imputaciones: Se conservan únicamente las correspondientes a las máquinas de la población de estudio. Se descartan además las imputaciones que registran incidencias. Estas capturan tiempos no productivos, así que no son útiles para el estudio.

Criterio máquina de mecanizado productiva: El estudio se restringe a las fases ejecutadas sobre máquinas de mecanizado productivas. Se entiende por tal aquella en

la que la variación del tiempo depende principalmente de la propia máquina, con escasa incidencia del operario. Se excluyen aquellas familias de máquinas que solo disponen de un equipo, además también se descartan las familias donde no existen máquinas equivalentes entre las que poder asignar una fase. Para este estudio la desviación entre tiempo real y teórico resulta informativa cuando existe una máquina concreta con alternativas equivalentes.

Ambos recortes concentran el análisis en las operaciones donde la asignación de máquina constituye una decisión real entre equipos equivalentes.

Este criterio ya definido en el apartado anterior responde a la naturaleza de la variable estudiada.

Máquinas y grupos: Se descarta una máquina registrada en el ERP sin equivalente en el MES, que por ello carece de imputaciones. Se detectaron también máquinas sin grupo asignado. Entre estas las que cumplen el criterio de *máquina de mecanizado productiva* y presentan imputaciones asociadas, recibieron un grupo acorde a su naturaleza, en consulta con el equipo de planta. Se identifican cinco máquinas asignadas a dos grupos de forma simultánea; en consulta con el equipo de producción en la planta, se redefinieron para pertenecer a un único grupo, permitiendo mantenerlas dentro del estudio.

Aplicando el criterio de selección se descartan aquellas familias donde no existen máquinas equivalentes entre las que poder asignar una fase. También quedan fuera los grupos destinados a programación, montaje o control de calidad. En estas máquinas la desviación de tiempos informa en gran medida sobre la variabilidad del factor humano, y no de la máquina. Se descartan asimismo las máquinas genéricas o auxiliares. Estas operan como recurso comodín en determinadas circunstancias. Aunque imputan sobre un recurso productivo, no identifican qué equipo ejecutó realmente el trabajo, por lo que impiden el análisis a nivel de máquina.

Por último, se eliminan cuatro familias cuyo volumen de imputaciones no resulta representativo: ninguna alcanza las doscientas imputaciones.

Limpieza Famílias y Máquinas	**Número de instancias**
Familias iniciales	57
Familias válidas	9
Máquinas iniciales	120
Máquinas en familias válidas	32

Ilustración 13: Tabla con la evolución de la población de estudio para las máquinas

4.3.2 Limpieza de los datos

La limpieza se aplica sobre los datos una vez ya seleccionados.

Fases imputadas en varias máquinas: Se identificaron 899 fases con imputaciones repartidas entre distintos equipos. Como se argumentó, su tratamiento exige determinar una máquina responsable del tiempo registrado. Para ello se establece un criterio de *máquina dominante*. Cuando más del 80% del tiempo imputado corresponde a un solo equipo, la totalidad de las imputaciones se atribuye a este. En caso contrario, la fase se descarta, al no poder asignarse el tiempo a un recurso concreto. El criterio resuelve el 33% de las 899, las restantes quedan fuera del conjunto. Este criterio ha sido consensuado con el equipo de producción.

Desglose de tiempos de preparación y producción: El registro del tiempo imputado se presenta en dos campos, tiempo de preparación y de producción. El tiempo de ambos componentes no resulta fiable. En ocasiones los operarios imputan tiempo de producción como preparación, y a la inversa. En consecuencia para el análisis deberá emplearse el tiempo total de la fase, sumado ambos campos.

Tiempos anómalos: La validación de los tiempos registrados en el MES reveló incoherencias entre el tiempo previsto y el tiempo total imputado. Las desviaciones más acusadas se concentran en fases con un número anormalmente elevado de imputaciones. La inspección de estos casos identificó su origen: en ocasiones una máquina permanecía con la orden abierta en el MES tras finalizar el trabajo efectivo, de modo que el sistema seguía acumulando tiempo sin actividad productiva asociada. Este tiempo infla de forma desproporcionada el total de la fase. Se adopta por ello un criterio de descarte: una imputación que supera la duración de tres turnos de ocho horas no puede considerarse válida. Ya que nunca una fase puede llegar a estar más de tres turnos activa en el taller.

Entonces la limpieza culmina en el resultado de la siguiente tabla. El mayor recorte se ha dado al seleccionar solo las imputaciones realizadas en las máquinas de la población de estudio. Con esto se han unido las tablas de EPR para las fases y las órdenes de fabricación, descartando aquellas que no aparecen en la tabla de imputaciones ya limpia.

Limpieza de tablas	**Número de instancias**
Imputaciones iniciales	140.485
Imputaciones limpias	59.570
El recorte aplicado a las imputaciones se propaga al resto de tablas. **Solo se conservan las fases que mantienen imputaciones válidas y, en consecuencia, las órdenes de fabricación a las que pertenecen.**	

Órdenes de fabricación antes del recorte	11.983
Órdenes de fabricación tras recorte	6.501
Fases de fabricación antes recorte	69.986
Fases de fabricación tras recorte	14.689

Ilustración 14: Instancias resultantes tras la limpieza

4.3.3 Preprocesamiento de datos

Algunas de las construcciones de datos de este apartado han servido de apoyo durante el proceso de limpieza.

Maestro de máquinas y grupos: Se construye una tabla que asocia cada máquina con su grupo, manteniendo una relación 1:1. Sobre ella se elabora una segunda, que vincula cada imputación con la máquina y el grupo en que se registró el trabajo. Esta última describe el reparto de la carga dentro de la población de estudio y permite verificar que todas las máquinas consideradas cuentan con imputaciones asociadas.

Tiempos ERP: Los tiempos teóricos los conserva el ERP, estos son atributos de cada fase. Se especifican en dos variables, y el sumatorio de ambas define el tiempo total previsto para una fase.

Nombre variable	**Contenido**
PreparationTime	Tiempo teórico de preparación
ExecutionTime	Tiempo teórico de ejecución o producción

Ilustración 15: Tabla de contenido con las variables del tiempo teórico

Tiempos MES: El MES registra el tiempo de cada imputación como tiempo de reloj en la variable *MinutosRealNbr*, es decir, el transcurrido entre el inicio y el fin marcados por el operario. Ese intervalo no equivale a la atención dedicada a la fase. Resulta habitual que un operario gestione varias máquinas de forma simultánea. Para reflejarlo, el MES almacena un porcentaje de dedicación por imputación *PorcentajeDedicacionNbr*, que reparte el tiempo del operario entre las tareas concurrentes. La distinción resulta determinante para la variable objetivo. El tiempo teórico del ERP asume dedicación plena, por lo que sólo admite comparación con el tiempo efectivo, y no con el tiempo bruto de reloj. El tiempo efectivo de cada imputación se obtiene aplicando sobre su tiempo bruto el porcentaje de dedicación correspondiente.

Agregación a nivel de fase: El MES registra la ejecución a nivel de imputación, de modo que una misma fase puede acumular varias imputaciones. La unidad de análisis

del estudio es la fase. Las imputaciones de cada fase se consolidan en un único registro.

La agregación responde a dos motivos. El primero atañe a la variable objetivo: el cociente entre tiempo real y teórico exige que ambos términos se definan al mismo nivel. El tiempo teórico se establece en el ERP por fase, de modo que el real debe consolidarse igualmente por fase. Sin esa consolidación existirían varios tiempos reales frente a un único teórico. El segundo motivo afecta al modelado: cada observación debe corresponder a una asignación de fase a máquina. Mantener las imputaciones sin agregar haría aparecer una misma fase en varias filas, con un peso desproporcionado durante el entrenamiento.

Entonces a partir de *MinutosRealNbr* se construyen dos variables de tiempo real:

Nombre variable	**Contenido**
MinutosRealNbr	Tiempo bruto registrado por MES para cada imputación
MinutosReal_total	Tiempo bruto registrado en la fase: $\sum_{i=1}^{n} MinutosRealNbr_i$
MinutosReal_efectivo	$\sum_{i=1}^{n} \left(MinutosRealNbr_i \cdot \frac{PorcentajeDedicacionNbr_i}{100}\right)$
Siendo n el número de imputaciones de la fase e i cada imputación.	

Ilustración 16: Tabla de contenido con variables creadas

La agregación conserva la información relevante de las imputaciones individuales. Además de la suma de tiempos, se mantienen los atributos constantes dentro de la fase, como la orden de fabricación o el material.

Integración de ambos sistemas: La tabla de fases depurada del ERP, que aporta los tiempos teóricos, se cruza con la tabla de imputaciones agregadas del MES. El enlace se resuelve mediante la tabla de mapeo. Tras el cruce se detectaron fases sin correspondencia en el ERP. Estas son de órdenes de fabricación excluidas por el filtro de fecha de finalización, cuyas fases quedan en consecuencia sin tiempo teórico asociado. Estas ya se han tenido en cuenta al dar los números limpios en el apartado anterior de *"limpieza"*.

Artículos: Se contemplan únicamente los artículos a fabricar. De ellos interesan su línea de producto y la familia, los dos niveles jerárquicos en los que el ERP clasifica los artículos. La materia prima consumida no se incorpora al modelo: un artículo a

fabricar consume siempre el mismo artículo de partida, por lo que su inclusión no aportaría información adicional.

4.3.4 Construcción de la variable objetivo

Como ya se ha definido, la variable objetivo se construye enfrentando el tiempo previsto en el ERP (teórico), frente al tiempo registrado en el MES (práctico). Los tiempos a tener en cuenta para formar el ratio son los siguientes:

$$ratio = tiempo\ real\ efectivo\ /\ tiempo\ teórico\ previsto$$

Variable en la fórmula	Variable en el código
$tiempo\ real\ efectivo$	*MinutosReal_efectivo*
$tiempo\ previsto$	*PreparationTime + ExecutionTime*
La obtención de cada "*Variable en el código*" se ha especificado en el apartado anterior.	

Ilustración 17: Variables de tiempo para calcular el ratio

Interpretación del ratio:

- Ratio = 1 tiempo real coincide con el teórico, la estimación se cumple.
- Ratio > 1 tiempo real superior al teórico, ha tardado más de lo previsto.
- Ratio < 1 tiempo real inferior al teórico, completado antes de lo estimado.

Para los datos de estudio el ratio presenta la siguiente distribución:

	Media	Desviación	Mínimo	Q1	Mediana	Q3	Máximo
Ratio	2,032	2,538	0,000114	0,968	1,464	2,345	150,617

Ilustración 18: Distribución del ratio

La mediana indica que la fase típica tarda casi un 50% más de lo previsto. La media queda muy por encima de la mediana y el máximo llega a un ratio de 150, lo que refleja una distribución con una cola larga hacia la derecha.

La exploración de la distribución del ratio revela la presencia de valores extremos en ambas colas, un mínimo próximo a cero y un máximo muy por encima del uno, incompatibles con desviaciones reales de rendimiento en producción. Esto es atribuible a las incidencias de calidad en los datos recogidos por MES. Estos casos deben investigarse antes de emplear el ratio como variable objetivo del modelo.

Cola Superior		Cola Inferior	
Ratio >= 5	798 fases (5,4%)	Ratio <= 0,5	885 fases (6,0%)
Ratio >= 8	259 fases (1,8%)	Ratio <= 0,3	404 fases (2,7%)
Ratio >= 10	152 fases (1,0%)	Ratio <= 0,2	260 fases (1,8%)
Ratio >= 15	63 fases (0,4%)	Ratio <= 0,1	158 fases (1,1%)

Ilustración 19: Inspección de las colas

Inspeccionando la relación entre las las colas y la duración de las fases se observa lo siguiente:

Tiempo previsto (min)	Fases	Ratio mediano	% en la cola
[2 – 15]	3.214	2,06	23,77
(15 – 30]	2.806	1,75	13,76
(30 – 60]	2.816	1,50	7,71
(60 – 108]	2.971	1,32	3,10
(108 – 9.060]	2.882	1,10	0,35

Ilustración 20: Inspección de colas en base los tiempos previstos

Cuanto más corta es la fase prevista, mayor es el ratio. Este comportamiento se explica por la propia sensibilidad del ratio como magnitud. Al ser un cociente sobre un tiempo teórico pequeño, una desviación de pocos minutos en una fase corta se traduce en una variación proporcional mucho mayor que la misma desviación en una fase larga. Para una fase corta una pequeña desviación tiene más peso en el crecimiento del ratio que en fases de mayor duración.

La naturaleza del propio ratio amplifica desviaciones que, en términos absolutos, son moderadas.

Esto tiene implicaciones tanto para la evaluación del modelo como para el proceso de modelado. Si el error se mide únicamente en términos de ratio, las fases cortas dominarán la métrica, y un modelo podría parecer poco preciso simplemente por fallar en estas fases, aunque su error en minutos sea reducido. Por ello, y siguiendo la recomendación de la tutora, el error debe reportarse también desagregado por rango de duración y en unidades de tiempo absolutas, no solo en ratio.

Inspeccionando instancias y trabajando con el equipo en fábrica, se determina que en la cola superior se encuentran ratios causados por imputaciones que no se cerraron a tiempo debido a errores humanos. En la cola inferior, en cambio, se encuentran imputaciones que se han utilizado para marcar el trabajo como realizado y declarar la producción, sin recoger el tiempo realmente dedicado a la fase. Por parte de la planta este es un mal hábito de uso si se busca recoger el tiempo real.

Para mitigar estas anomalías y descartar ratios atípicos se establecerá un umbral de corte. Ya se ha expuesto que el ratio es una magnitud multiplicativa, expresa cuántas veces el tiempo real excede o queda por debajo del teórico. Su distribución es, por tanto, asimétrica: no admite valores negativos, pero puede crecer sin límite.

La transformación logarítmica corrige esta asimetría. Por ello, el corte se aplica mediante el rango intercuartílico (IQR) sobre el logaritmo del ratio.

$$IQR = ln(Q3) - ln(Q1)$$

$$L = ln(Q1) - 1,5 \cdot IQR \rightarrow UMBRAL\ INFERIOR = e^{L}$$

$$U = ln(Q3) + 1,5 \cdot IQR \rightarrow UMBRAL\ SUPERIOR = e^{U}$$

Se considera atípico todo valor que se aleja de los cuartiles Q1 y Q3 más de 1,5 veces el IQR, criterio habitual en la detección de valores atípicos [Tukey, 1977]. El intervalo admisible debe calcularse con los datos de entrenamiento, para evitar *data leakage*. Esto se abordará en el modelado, junto con la partición de los datos.

Estudiando la distribución por cada familia de máquinas obtenemos esta representación:

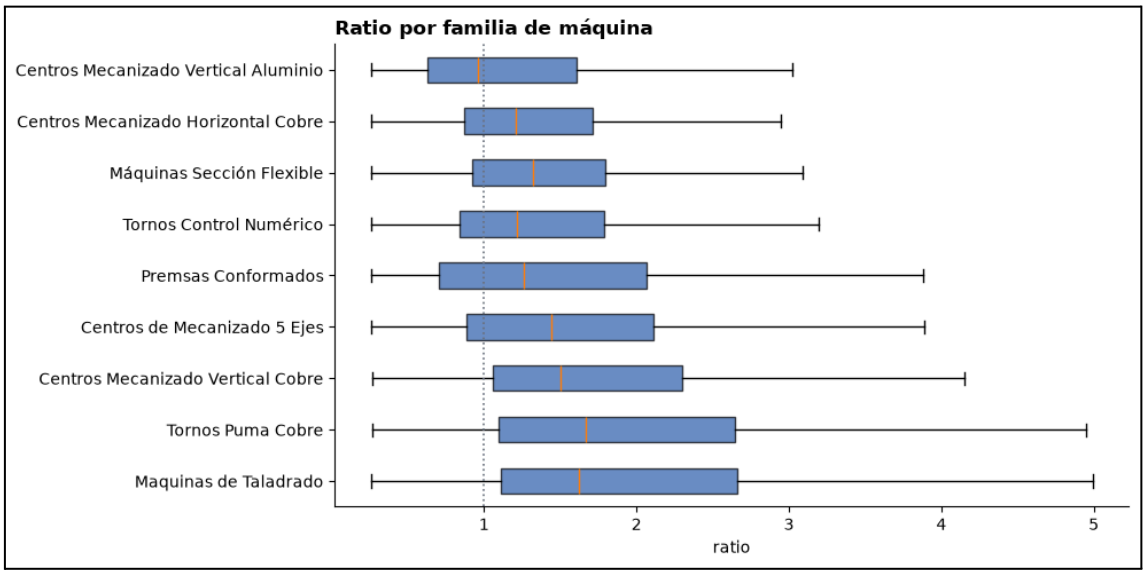


Ilustración 21: Distribución del ratio por familia (grupo) de máquinas

El análisis del ratio por familia de máquina confirma, con una vista más general, el patrón detectado en el estudio de la cola alta: las familias Màquines de Taladrat Profund (a la que pertenece TP02) y Torns Puma Cobre (a la que pertenece TN09) son las que presentan una mediana de ratio más alta de todo el dataset, muy por encima del resto.

Para el ratio lo visto hasta ahora permite intuir una infravaloración de tiempo sistemática por parte del ERP. La mediana del ratio se sitúa por encima de 1 en todos los segmentos analizados hasta ahora.

Inspeccionando la distribución mensual del ratio, no se aprecia un patrón temporal claro ni cambios de nivel marcados a simple vista.

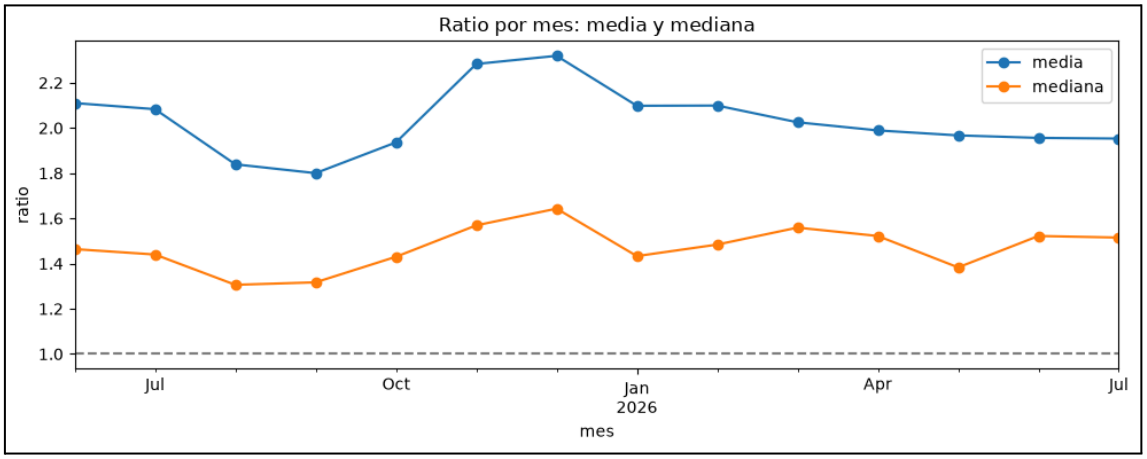


Ilustración 22: Evolución temporal del ratio

El ratio se mantiene por encima de 1 en todos los meses, esto parece ser un sesgo hacia tiempos reales superiores a los teóricos, ya que es persistente y no responde a un periodo concreto. La media y la mediana evolucionan de forma prácticamente paralela mes a mes, lo que indica que la asimetría de la distribución también es estable en el tiempo.

La estabilidad del ratio a lo largo del tiempo refuerza la idea de entrenar con los meses anteriores y evaluar con los posteriores haciendo un split temporal.

4.3.5 Conjunto final

El proceso de depuración final deja nueve familias de máquinas con capacidad de elección efectiva y volumen suficiente de registros.

La inspección del número de fases por máquina muestra un salto claro entre las máquinas con actividad habitual, que acumulan decenas o cientos de fases, y un pequeño grupo con apenas registros. Este hueco permite fijar un umbral de corte en 30 fases. Las máquinas por debajo del umbral se agrupan en una categoría "Otras" dentro de su familia (*otras_familia*), conservando su familia de máquina como variable,

de forma que el modelo pueda seguir aprovechando esa información aunque no disponga de un patrón específico por máquina. Es la mejor opción para no descartar estos datos. En un uso práctico futuro, a medida que estas máquinas registren más imputaciones, pasarán a tener su propia categoría.

Familias de máquinas	**Número de máquinas**
Torns Puma (Taller COURES) / TPU	2
Màquines de Taladrat Profund / MTP	2
Centres de Mecanitzat Vertical COURES / CV	4
Torns Control Numèric / TCN	4
Centres de Mecanitzat Horitzontal COURES / CH	3
Centre de Mecanitzat 5 Eixos petites / C5	4
Centres de Mecanitzat Vertical ALUMINIS / CV-ALU	3
Premses Conformats / CON	2
Màquines Secció Flexibles / FLEX	4
Total màquinas:	**28**

Ilustración 23: Recuento de máquinas por familias

Para el conjunto de máquinas consideradas en el estudio, la cantidad final de registros se distribuye de la siguiente manera:

Tabla	**Número de instancias**
Órdenes de fabricación	6.501
Fases de fabricación	14.689
Tipos de fases de fabricación	38
Líneas de artículos	17
Familias de artículos	44

Ilustración 24: Población de estudio final

Respecto a la selección de atributos, buena parte de las variables disponibles se descartaron por no aportar información relevante para el entrenamiento. Como se

expuso en la descripción de los datos, ambos sistemas emplean numerosos campos internos para su funcionamiento, sin utilidad para este estudio. Además, cada entidad dispone de varios campos que la identifican: nombre, código y GUID. Se conserva uno solo por entidad, pues los demás repiten la misma información.

Para evitar la fuga de información (*data leakage*) se adopta un criterio explícito: solo se emplean variables disponibles en el momento de planificar. Toda información que únicamente se conoce tras la ejecución queda excluida del entrenamiento. Por este motivo una vez calculado el ratio de cada fase, se descartan las variables de tiempo registradas en el MES.

Los atributos del conjunto de datos final se resumen en la siguiente tabla. Las celdas sombreadas corresponden a variables que no intervienen en el entrenamiento. Se conservan como identificadores o como referencia temporal para la partición de los datos.

Atributo	**Función**	**Explicación**
ratio	Objetivo (*y*) - numérica	Desviación a predecir
CodigoMaquina	Variable (*x*) - categórica	La asignación de la máquina para la fase a realizada
Familia Maquinas	Variable (*x*) - categórica	Agrupa máquinas equivalentes, permite compartir patrones entre ellas
TipoFase	Variable (*x*) - categórica	Tipo de fase de producción
TiempoPrevisto	Variable (*x*) - numérica	Tiempo teórico, estimación definida en el ERP, conocida al planificar
Quantity	Variable (*x*) - numérica	Cantidad a fabricar
Línea Producto	Variable (*x*) - categórica	Grupo al que pertenecen los artículos
Família Producto	Variable (*x*) - categórica	Subgrupo a que pertenecen losl artículos
fecha_fase	Identificador	Permite identificar el orden temporal
smOrdenId	Identificador	Identificador de la Orden de fabricación
IDMOTask	Identificador	Identificador de la fase de fabricación

Ilustración 25: Tabla de atributos finales

Esta selección de atributos no es definitiva. La ingeniería de variables (*feature engineering*) es un proceso iterativo que depende del modelo empleado [Zheng & Casari, 2018]. Cada algoritmo trata de forma distinta las variables categóricas y puede beneficiarse de una configuración propia. Por ello, el conjunto aquí descrito constituye el punto de partida del modelado, y su ajuste para cada algoritmo se aborda en la fase siguiente.

4.3.6 Justificación viabilidad de los datos

El proceso de preparación ha transformado los registros brutos de ambos sistemas en un conjunto apto para el modelado. Cada etapa responde a una exigencia concreta del problema planteado.

La selección ha acotado el conjunto a la población de estudio. Se conservan únicamente las fases ejecutadas en máquinas de mecanizado productivas, agrupadas en familias con capacidad real de elección. Este recorte garantiza que cada registro corresponde a una asignación entre equipos equivalentes, que es el escenario donde la estimación de la desviación aporta más información al planificador.

La limpieza ha eliminado las fuentes de distorsión identificadas en la comprensión de los datos. Se han descartado los registros del periodo de implantación, las incidencias, las fases fuera del estudio y los tiempos derivados de errores de registro. Con ello, en la medida de lo posible, los tiempos reales conservados reflejan el trabajo productivo efectivo. Queda pendiente aplicar el umbral de corte logarítmico (IQR) que deberá calcularse con los datos en train, se abordará junto con el split de datos.

La construcción ha dotado a ambos tiempos de un significado comparable. El tiempo real se ha corregido por la dedicación del operario y se ha consolidado a nivel de fase. El tiempo teórico se ha obtenido desde sus dos componentes del ERP. Sobre esa base se ha calculado la variable objetivo y se han acotado sus valores atípicos.

Por último, el conjunto final solo incorpora variables conocidas en el momento de planificar. Este criterio evita la fuga de información y asegura que el modelo reproduzca las condiciones reales de uso.

A la vista de lo expuesto, el conjunto resultante representa el comportamiento del taller en el ámbito del estudio. La premisa central del trabajo se mantiene: existe una decisión de asignación con alternativas reales, y los datos disponibles permiten estimar la desviación asociada a cada una. El planteamiento resulta, en consecuencia, viable para abordar la fase de modelado.

4.4 Modelado

4.4.1 Planteamiento del problema de modelado

Volviendo al foco en el problema, este se ha formulado como una tarea de regresión supervisada. A partir de las variables disponibles en el momento de planificar una fase, el modelo estima la relación entre el tiempo teórico previsto y el tiempo real efectivo para una fase en una máquina concreta.

Como se expuso en el marco teórico, el planteamiento se sitúa en el nivel predictivo de la analítica de datos y no en el prescriptivo. En términos operativos, el modelo recibe una combinación concreta de fase-máquina y devuelve la desviación esperada respecto al tiempo teórico. No propone ninguna asignación, la decisión final permanece en manos del empleado planificador.

Como se ha explicado, esta formulación condiciona la selección de variables de entrada. Solo se admiten aquellas disponibles en el momento en que la planificación tiene lugar, criterio que excluye cualquier información generada durante o después de la ejecución de la fase.

4.4.2 Variable objetivo: ratio frente a logaritmo del ratio

La variable objetivo es el ratio entre el tiempo real y el tiempo previsto de cada fase. Durante la preparación de los datos se identificó ruido sistemático en los datos. Para el desarrollo del modelo se plantea probar el entrenamientos con el ratio transformado al logaritmo. Esta versión presenta una distribución más simétrica y sobre todo reduce peso de los ratios más elevados.

Entonces, el logaritmo comprime los valores altos del ratio, de modo que las fases con desviaciones extremas tienen menos influencia en el ajuste del modelo. Con esta transformación, el modelo se centra más en el comportamiento habitual de las fases, quitando peso a los casos más extremos.

Este hallazgo incita a entrenar los modelos con ambas variables, el ratio y su logaritmo, para determinar si esta transformación mejora el rendimiento. Para que la comparación sea justa todos los modelos se evalúan en la misma escala. Las predicciones obtenidas con el logaritmo se devuelven a la escala del ratio mediante la función exponencial. Para poder calcular las métricas de error de forma equiparable entre ambas magnitudes.

Los siguientes gráficos muestran la distribución del ratio y del logaritmo del ratio en los datos de desarrollo. La línea roja vertical representa un ratio para tiempos igual a los que planea ERP.

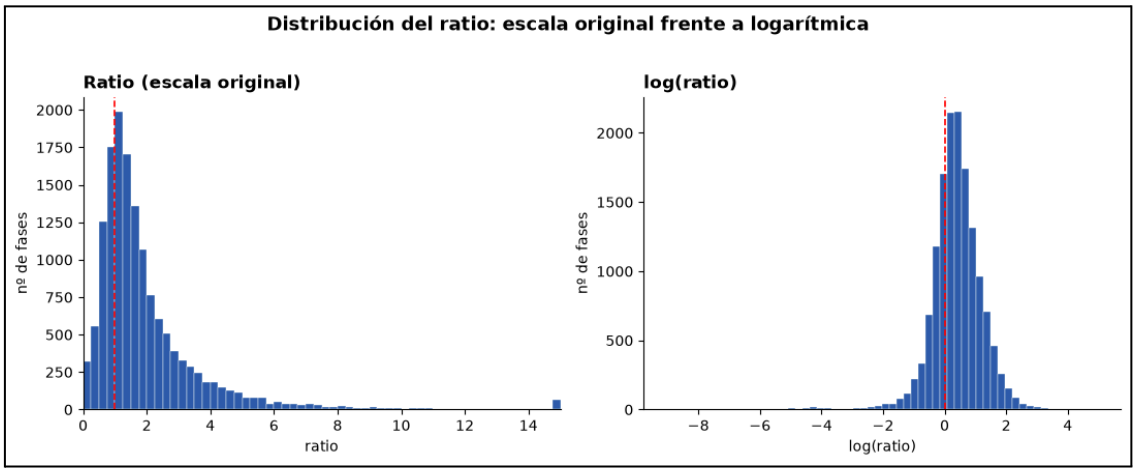


Ilustración 26: Distribución del ratio y del logaritmo del ratio

En ambas escalas se aprecia un desplazamiento hacia la derecha respecto a la previsión del ERP. Esto refuerza un posible sesgo, esto se tiene en cuenta para formar los baselines con los que comparar el modelo. Las distribuciones tienen las dos colas cortadas. Esto se debe a la limpieza de outliers realizada con el corte IQR.

Interesa entender la asimetría del ratio.

Fórmula asimetría: $$g_1 = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{\left(\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{3/2}}$$

n: número de fases intervalo desarrollo.

x_i: es el valor de la fase **i**, con **i = 1, …, n**.

$\bar{x}$: es la media de los **n** valores.

$x_i - \bar{x}$: desviación de cada fase respecto a la media.

g1: convenio estadístico para asimetría.

La asimetría del ratio es de 1,94, fuertemente alta. Supera el valor de 1, a partir del cual se considera una asimetría fuerte, visualmente se aprecia en los gráficos con una larga cola a la derecha. El logaritmo reduce esta asimetría a 0,14. Como se esperaba presenta una distribución mucho más simétrica.

Aunque el logaritmo del ratio presente una distribución más simétrica, eso no implica que el modelo vaya a predecir mejor con esa variable. La elección se hará comparando los modelos ante los datos de validación.

4.4.3 Estrategia de validación y métricas

Métricas

La literatura reforzaba el uso de MAPE, MAE o RMSE. La métrica principal escogida es el error absoluto medio (MAE) y para complementar el análisis se tomará la raíz del

error cuadrático medio (RMSE). Las dos se calculan en escala ratio. Se ha descartado MAPE porque esta trabaja con el error en términos relativos, y el ratio de por sí ya es un error relativo, siendo entonces redundante.

El prototipo está pensado para estimar la desviación de cada fase por separado. Por eso el MAE es la métrica principal: mide cuánto se equivoca el modelo en la fase típica. El RMSE penaliza más los errores grandes y muestra cómo se comporta el modelo en las fases con desviaciones importantes.

Relación entre la variable objetivo y las métricas

En la versión ratio, el modelo calcula la media de los ratios, es decir, una media aritmética. En la versión log(ratio), el modelo calcula la media de los logaritmos de los ratios y, al deshacer la transformación mediante la exponencial, el resultado es una media geométrica.

El logaritmo comprime los valores altos. Entonces las fases con desviaciones extremas pesan menos en la media geométrica que en la aritmética, y la media geométrica queda siempre por debajo de la aritmética o igual. Como el ratio tiene una cola larga hacia valores altos, la predicción de la versión log(ratio) queda más cerca de la fase típica y más lejos de las fases extremas.

Cada versión encaja mejor con un objetivo distinto:

Variable objetivo	Objetivo	Métrica referencia
log(ratio)	Acertar la duración de la fase habitual	MAE
ratio	Acertar la duración media, incluidas las fases con desviaciones grandes	RMSE

Ilustración 27: Tabla resumen variable objetivo ratio vs logaritmo

Partición de los datos

La naturaleza temporal de los datos exige una partición cronológica. Una partición aleatoria sería un problema, ya que permitiría que el modelo entrenase con fases posteriores a las que debe predecir. El campo *fecha_fase* permite identificar la fecha en que se empezó la fase de fabricación.

Entonces el modelo se entrena con el pasado y se evalúa sobre el futuro. Esta decisión va acorde con la premisa del modelo, este debe hacer la inferencia sólo contando con información disponible en el momento de la planificación, por lo tanto, no puede ver datos del futuro.

La partición se realiza a nivel de orden de fabricación y no de fase. Las fases de una misma orden comparten contexto, de modo que repartirlas entre conjuntos distintos filtraría información entre ellos. Cada orden se asigna al bloque temporal correspondiente a la fecha de su primera fase. Para obtener el intervalo temporal de una orden se toma la fecha de la primera fase y de la última. De esta forma se evita que fases de una misma orden puedan aparecer en particiones distintas. De media las órdenes de fabricación suelen durar 6 días, el 75% no supera los 10 días entre su primera y última fase. El caso más extremo presente llega a los 61 días. La duración de las órdenes no está correlacionada con la acumulación de tiempo en sus fases. Algunas órdenes pasan mucho tiempo en el taller por su propia naturaleza.

La distribución de datos entre meses se muestra estable en el tiempo:

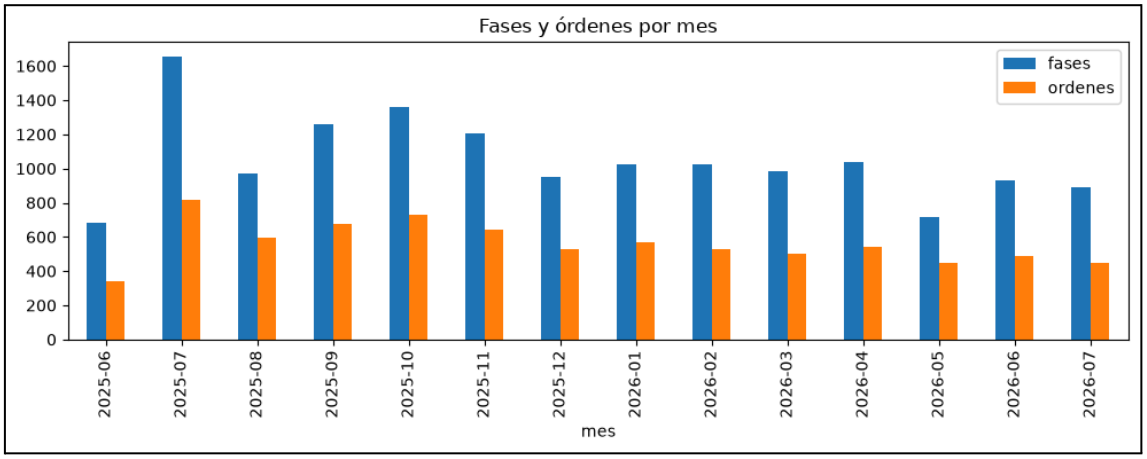


Ilustración 28: Reparto de fases y órdenes de fabricación por mes

Entonces la totalidad de datos abarca 14 meses. La partición se hará a nivel de mes. El corte se sitúa en el 1 de mayo de 2026. El conjunto de desarrollo abarca de junio de 2025 a abril de 2026.

Partición	Meses	Intervalo Temporal	Cantidad de fases
Desarrollo	11	[06/2025 - 05/2026)	83,3%
Test	3	[05/2026 - 07/2026]	16,7%

Ilustración 29: Reparto de las fases entre desarrollo y test

Las órdenes iniciadas antes del corte se asignan íntegramente al conjunto de desarrollo, aunque algunas de sus fases se ejecutasen con posterioridad. Esta situación afecta a 78 fases. Mantener cada orden completa en un mismo conjunto evita que las fases de una misma orden, que comparten contexto, se repartan entre desarrollo y test. Se acepta, en consecuencia, que una proporción reducida de la

información del conjunto de desarrollo corresponda a fechas posteriores al corte para evitar filtrado de información.

Se detectan 2 máquinas con presencia en los datos de test pero no en desarrollo, ha estas se las marca con un variable para poder identificarlas posteriormente. Esta variable no se emplea para el entrenamiento, solo para identificar cómo se ha comportado el modelo con datos no vistos en entrenamiento.

Validación cruzada temporal

En cada fold el modelo se entrena con todos los meses anteriores al mes de validación y se evalúa sobre ese mes (febrero, marzo y abril de 2026). A diferencia de la validación cruzada aleatoria, este esquema respeta el orden temporal de los datos y evita que el modelo utilice información futura durante el entrenamiento.

Para el desarrollo del modelo se ha decidido utilizar validación cruzada temporal con ventana expansiva con tres folds. Esto supone que de los once meses de desarrollo ocho serán íntegros para entrenamiento y 3 se destinan a la validación. A diferencia de la validación cruzada aleatoria, este esquema respeta el orden temporal de los datos y evita que el modelo utilice información futura durante el entrenamiento.

Validación cruzada (k=3)										
06/25	07/25	08/25	09/25	10/25	11/25	12/25	01/26	02/26	03/26	04/26
Entrenamiento k1								valid		
Entrenamiento k2									valid	
Entrenamiento k3										valid

Ilustración 30: Validación cruzada reparto de folds

Aplicar el umbral de corte

En el estudio del ratio se detectó que el conjunto de datos, para el radio, existen colas en ambas direcciones las cuales acumulan erróneos.

En ese momento se determina que es necesario aplicar un umbral de corte en ambas colas para reducir errores acumulados. Este umbral de corte debe calcularse en Train y aplicarse con esos valores sobre Validación y Test.

Los umbrales calculados en train presentan 0.259 para el umbral bajo y 8.558 para el alto. Aplicar este corte a todo el dataset reporta lo siguiente:

Cola	Fases descartadas
cola alta (>= 8.558)	211
cola baja (<= 0.259)	332
Fases finales:	14.146

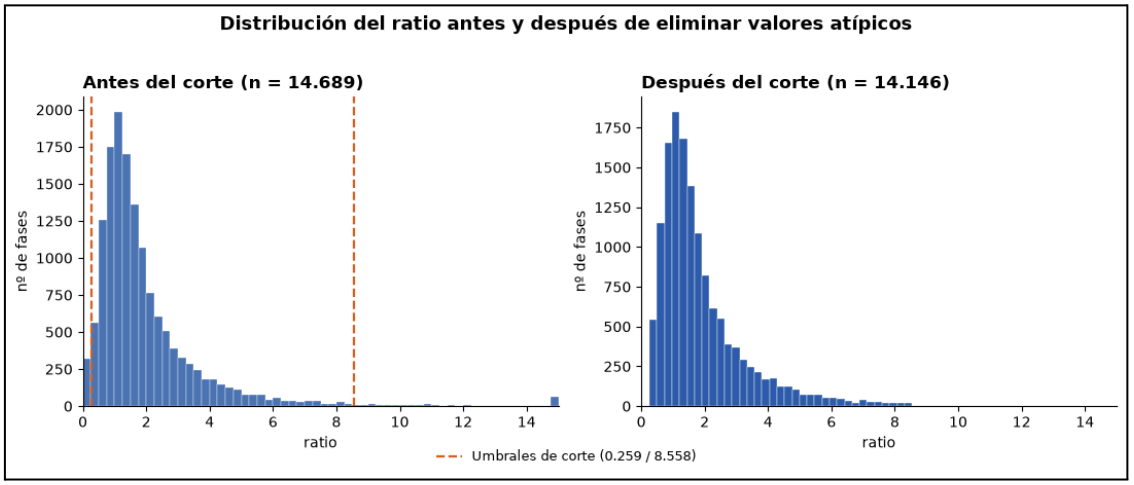


Ilustración 31: Fases descartadas por umbral de corte

Visualizando la distribución de los datos con el corte ya aplicado en ambas distribuciones del ratio, el conjunto sigue presentando una tendencia clara hacia la derecha respecto lo previsto por el ERP (línea roja).

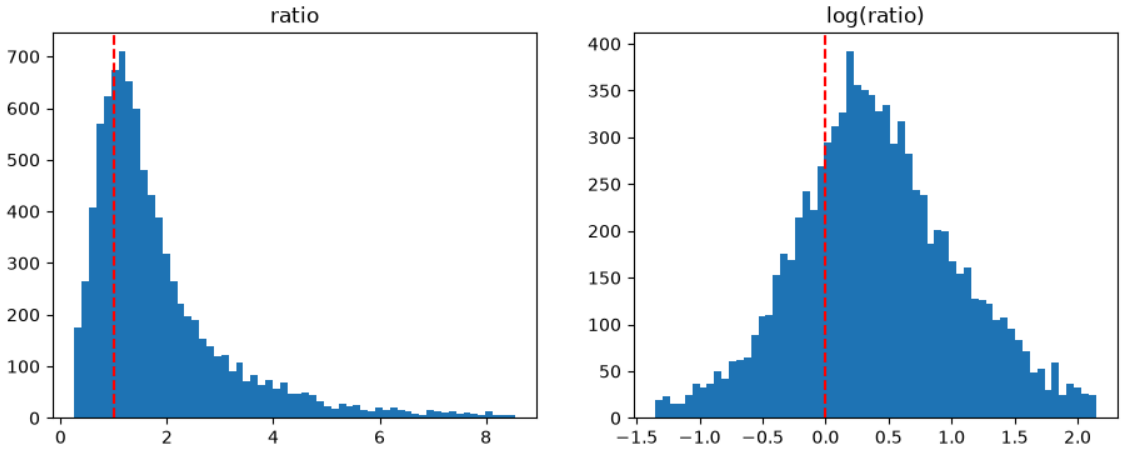


Ilustración 32: Distribución del ratio entre las dos escalas con umbrales de corte aplicados

4.4.4 Baseline

La comparación de cualquier modelo exige una referencia previa. Sin ella no es posible determinar si la capacidad predictiva obtenida aporta algo sobre la situación de partida.

Baseline	Suposición	Implementación	Resultado de superarlo
B0	ERP acierta	Predice ratio = 1 para todas las fases	El modelo mejora la planificación actual del ERP
B1	ERP planifica con un sesgo general	Predice la misma constante para todas las fases	El modelo aporta más que corregir el sesgo general
B2	El sesgo depende de la familia o de la máquina	Predice una constante por grupo (familia o máquina)	El modelo aporta más que una tabla de consulta por grupo

Ilustración 33: Tabla resumen de los baselines para entender su objetivo

Los baselines se calculan con los datos de entrenamiento, y se evalúan en validación y en test, igual que los modelos, para poder llegar a compararse con ellos. A continuación se estudiará cada baseline independientemente, los resultados de cada uno se medirán contra MAE y RMSE.

Primer baseline: B0

La idea de un ratio igual a uno representa la planificación actual del sistema. El ERP asume que cada fase consume exactamente su tiempo teórico. Superar esta referencia equivale, por tanto, a demostrar que los datos históricos aportan información que la planificación actual no recoge.

Este es el baseline que se tendrá en cuenta para afrontar la hipótesis, así mismo los dos baselines adicionales –B1 y B2– ayudan a estudiar el desempeño del modelo con mayor criterio.

bloque	ratio	MAE B0	RMSE B0
k1	1	1,140	1,779
k2	1	1,086	1,672
k3	1	1,092	1,680
test	1	1,019	1,585

Ilustración 34: Estudio del MAE y RMSE para el baseline B0 en validación y test

Los valores de MAE y RMSE son notablemente altos. Se mantiene en torno al 1,1. Esto supone que de media el tiempo real se aleja del teórico en un 110% del tiempo teórico. Es un resultado que podría estar alineado con la idea de que el tiempo teórico se queda corto respecto al real. Los valores de RMSE se mantienen en torno al 1,6 esto indica que los tiempos teóricos contienen errores grandes al enfrentarlos con los prácticos.

La separación entre MAE y RMSE remarca el hecho de que hay errores grandes en la planificación, podemos entender esto como que el error no es homogéneo. Hay fases que se equivocan poco y algunas que se equivocan mucho. Esto encaja con el estudio de las colas del ratio, donde un grupo de fases mantenía valores muy altos sin ser outliers.

Estos resultados hay que mirarlos con profundidad. Un MAE alto puede deberse a dos cosas: sesgo o dispersión en la planificación de los tiempos teóricos. Debe estudiarse este fenómeno. Para ello se calcula el error medio, para observar hacia donde se equivoca la mediana para MAE.

El error medio se calcula como: $(1/n) \cdot \Sigma\,(1 \;-\; r_{\mathrm{i}})$

Bloque	Error medio	Ratios > 1	Mediana ratio	Media ratio	Diferencia
k1	-1,008	75,08%	1,539	2,008	0,469
k2	-0,959	78,85%	1,584	1,959	0,375
k3	-0,940	74,46%	1,533	1,940	0,406
test	-0,883	75,26%	1,489	1,883	0,395

Ilustración 35: Estudio del error medio de MAE para B0 en validación y test

Estos resultados apuntan hacia un sesgo, ERP se queda corto en sus estimaciones de tiempo. Aproximadamente el 75% de las fases tienen un ratio superior a 1, es decir, 3 de cada 4 fases tardan más de lo planificado. La mediana con un ratio de 1,5 indica que el tiempo práctico de una fase típica supera un 50% al teórico. El error medio se mantiene en torno al -0,9. Esto refuerza que haya un sesgo hacia un tiempo teórico menor al práctico.

Analizando la relación entre la media y la mediana del ratio se aprecia que la media queda claramente por encima de la mediana en todos los bloques, unos 0,4 puntos sobre el ratio. Como ya se detectó al estudiar el ratio, la distribución de este es asimétrica, con cola a la derecha. Hay un grupo de fases con ratios muy altos que tira de la media hacia arriba. La asimetría es estable entre los bloques.

Haciendo el mismo estudio pero para el logaritmo del ratio, en vez del ratio, se obtienen resultados similares dentro del umbral de escalar del logaritmo, exceptuando la diferencia entre media y mediana. Concretamente la media y la mediana convergen. Su diferencia es mínima en comparación con los resultados del ratio sin logaritmo. Esto apunta a que el log(ratio) es mucho más simétrico que el ratio, algo que ya se expuso en el apartado *construcción de la variable objetivo*. La cercanía entre media y mediana es un indicio de simetría, no una prueba completa.

Cabe destacar que esta notable simetría en la escala del logaritmo hace pensar que las desviaciones son de tipo multiplicativo. Entendiendo como desviación la diferencia entre real y teórico. Entonces aquí lo que vemos es que el log altera la escala en la que se miden las desviaciones, y en esta escala se comportan de una forma más simétrica. Aun así, el sesgo sigue presente: el 75% de las fases mantiene log(ratio) > 0, equivalente a ratio > 1. El log cambia la forma de la distribución, pero no elimina el sesgo.

Este descubrimiento refuerza la decisión de implementar los dos baselines adicionales.

Segundo baseline: B1

El análisis de B0 ha mostrado un aparente comportamiento sesgado. El ERP no se equivoca por igual hacia los dos lados, sino que su previsión de tiempos se queda corta de forma sistemática. Esto motiva el segundo baseline. B1 sustituye ese valor unitario por una constante estimada a partir de los datos.

Entonces B1 admite que puede existir una desviación sistemática y la incorpora como corrección fija. En lugar de predecir ratio = 1, predice para todas las fases el ratio típico observado en entrenamiento. Se calcula para las dos versiones: la mediana, asociada al MAE y la media, asociada al RMSE a nivel global.

Bloque	Ratio mediano	MAE B1	Ratio medio	RMSE B1
k1	1,447	1,021	1,857	1,474
k2	1.453	0,928	1,877	1,373
k3	1.466	0,967	1,879	1,394
test	1.470	0,904	1,884	1,316

Ilustración 36: Estudio del MAE y RMSE para el baseline B1 en validación y test

Las medias y medianas de B1 son estables entre bloques, y la media queda siempre por encima de la mediana, lo que confirma la asimetría del ratio. B1 reduce el error de B0 en todos los bloques, tanto en MAE como en RMSE. Esto indica que corregir sólo el sesgo general, sin usar variables, ya mejora la planificación del ERP.

Si los modelos superan a B0 puede deberse únicamente a corregir el sesgo. Superar a B1, en cambio, indica que las variables aportan información adicional sobre la desviación de cada fase.

El tercer baseline (B2) extiende esta idea aplicando un sesgo distinto para cada grupo de máquinas, en lugar de uno común para todas.

Tercer baseline: B2

La tercera referencia, B2, calcula la constante por grupos en lugar de para el conjunto completo, empleando variables como la máquina o la familia de máquinas. A diferencia de las anteriores, B2 ya utiliza información de las variables de entrada, y equivale a una tabla de consulta construida a partir del histórico. Si los modelos no superan esta referencia, cabe concluir que existe señal en los datos, pero que una regla sencilla la recoge casi por completo.

Es necesario decidir la variable bajo la que agrupar los datos, para ello es importante tener en cuenta cómo distribuyen los datos las distintas posibles agrupaciones.

Agrupación	num. grupos	grupos con <30 fases	% grupos <30 fases
Máquina	24	3	0,4
Familia máquinas	9	0	0
Tipo fase	38	17	1,8
Familia × tipo fase	94	69	4,1

Ilustración 37: Inspección orientativa de las variables consideradas en train

Las variables en torno a la máquina són las más interesantes para estudiar b2.

- *Máquina*: aporta más detalle. Si dos tornos de la misma familia se comportan distinto, esta variable lo recoge.
- *Familia máquinas*: más estable ya que no presenta ningún grupo pequeño, pero trata igual a todas las máquinas de una misma familia.

Entonces B2 asigna a cada fase la mediana y la media del ratio de su grupo en el entrenamiento. Cuando un grupo no tiene suficientes datos la fase recibe la constante global del entrenamiento, es decir, la misma predicción que B1. Así, todas las fases reciben predicción y se evalúan. Entonces a nivel de fase B2 recurre a B1 cuando no dispone de información suficiente sobre el grupo. Esto realmente solo sucederá en el caso de la máquina, ya que la tabla anterior muestra que para familia no se dan casos.

Bloque	MAE B2 familia	MAE B2 máquina	RMSE B2 familia	RMSE B2 máquina
k1	0,99	0,98	1,45	1,42
k2	0,89	0,88	1,33	1,32
k3	0,94	0,92	1,36	1,34
test	0,88	0,86	1,29	1,26

Ilustración 38: Estudio del MAE y RMSE para el baseline B2 en validación y test

Los resultados de B2 reducen el error de B1 en todos los bloques, tanto en MAE como en RMSE. Asignar un sesgo distinto a cada grupo mejora la corrección frente a un sesgo común para todas las fases. B2-máquina obtiene menor error que B2-familia en todos los bloques, aunque la diferencia es pequeña.

Este gráfico ayuda a explicar en parte la mejora que supone B2 frente a B1.

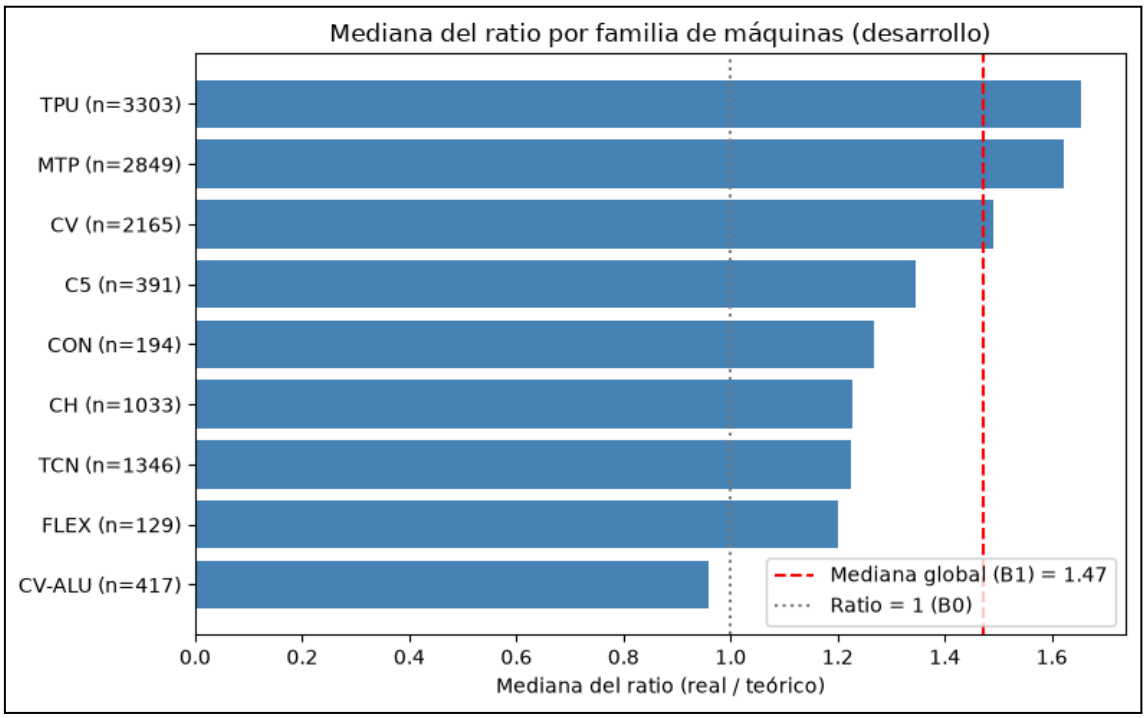


Ilustración 39: Mediana del ratio por familias para los datos de desarrollo

Las familias de máquinas que agrupan una mayor cantidad de fases a su vez presentan una mediana más alta, esto desplaza la mediana global.

Resumen de los Baselines

La siguiente gráfica muestra la evolución de los resultados ya expuestos de cada baseline:

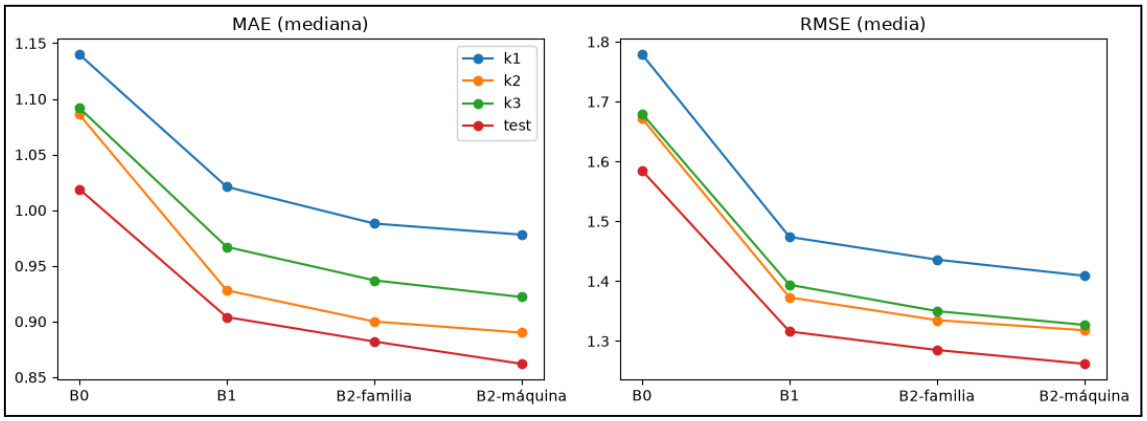


Ilustración 40: evolución del MAE y RMSE para cada baseline

En todos los bloques y en ambas métricas el error disminuye en cada escalón. B2-máquina es el baseline con menor error en todos los bloques y se toma como listón más exigente para los modelos. B1 se mantiene como referencia para separar la corrección del sesgo global del aporte de las variables.

4.4.5 Modelos considerados

En este apartado se describen los modelos utilizados para predecir el ratio entre el tiempo real registrado en el MES y el tiempo teórico del ERP en cada fase. Para cada modelo se aborda su explicación, cómo se han preparado las variables, qué experimentos se han hecho con la selección de hiperparámetros y qué resultados se han obtenido en validación.

Se han elegido pocos modelos y de complejidad creciente. Primero una regresión Lineal Ridge, después dos modelos basados en árboles, Random Forest y LightGBM. Con estos dos se comprueba si captar relaciones no lineales e interacciones entre variables mejora la estimación respecto al modelo lineal. Debido a la cantidad de datos disponibles en la población de estudio se ha descartado trabajar con redes neuronales, estas requieren de una mayor cantidad de datos.

Tipo Variables	Variables
Variables categóricas	CodigoMaquina, Familia Maquinas, TipoFase, Línea Producto y Família Producto.
Variables numéricas	TiempoPrevisto y Quantity.

Ilustración 41: Variables de entrenamiento

Las fases sin *Línea Producto* o *Família Producto* se agrupan con la etiqueta "Desconocida". Los hiperparámetros de cada modelo se eligen según el menor MAE medio de los 3 folds. El MAE en entrenamiento se usa como apoyo para detectar sobreajuste.

Los tres modelos trabajan reduciendo el error cuadrado (L2), adicionalmente LightGBM también se prueba con L1.

Regresión Ridge

La regresión Ridge es el primer modelo de estudio. Actúa como referencia interpretable frente a los modelos no lineales posteriores. Este incide en una relación lineal entre las variables de planificación y el ratio. Ridge es una regresión lineal que penaliza el tamaño de los coeficientes:

$$min_{\beta} \sum_{i} (y_i - \hat{y}_i)^2 + \alpha \sum_{j} \beta_j^2$$

Algunas variables de entrada tienen una estructura jerárquica. Cada máquina pertenece a una única familia de máquinas y cada familia de producto pertenece a una única línea de producto. Tras la codificación one-hot, parte de las columnas pueden resultar redundantes entre sí. Esta redundancia genera multicolinealidad, que en una regresión ordinaria provoca coeficientes inestables. La ventaja de la penalización que aplica Ridge estabiliza los coeficientes y reparte el efecto entre las variables relacionadas. Además, la codificación one-hot genera un número elevado de columnas y la penalización reduce también el riesgo de sobreajuste. Su principal limitación es que solo capta relaciones lineales. No modela interacciones entre variables, salvo que se definan explícitamente.

Las variables categóricas se codifican con one-hot. Las categorías con menos de 30 fases en entrenamiento se agrupan como infrecuentes, y las categorías no observadas en entrenamiento se asignan a ese mismo grupo. Para las variables numéricas todas las transformaciones se ajustan únicamente con los datos de entrenamiento de cada fold, para evitar fugas de información hacia la validación. Para facilitar el trabajo y dar el mismo tratamiento en todos los folds, se emplea ColumnTransformer y Pipeline de la librería sklearn.

- *Experimentar con los Hiperparámetros Linear Ridge*

El modelo se entrena con dos formulaciones de la variable objetivo: ratio y log(ratio). En la versión log(ratio), las predicciones se devuelven a escala ratio con la exponencial antes de calcular las métricas. Para la elección de los hiperparámetros cada versión se han probado seis valores de α, cada uno 10 veces mayor que el anterior. El criterio de elección es el menor MAE medio en validación.

Entrenando el modelo con las dos versiones del ratio aparece el mismo comportamiento. Para valores bajos de α el MAE medio se mantiene prácticamente constante y forma una meseta. A partir de α = 100 el error aumenta: con tanta penalización el modelo pierde parte de la información de las variables. El comportamiento se repite en los 3 folds, así que la elección no depende de un mes concreto.

Se adopta α = 1 en ambas versiones, un valor situado dentro de la meseta. Esta coincidencia en α permite que la única diferencia entre las dos versiones sea la variable objetivo. Dentro de la meseta las diferencias de MAE son de milésimas, por lo que el modelo es robusto a la elección de α.

- *Validación Linear Ridge*

fold	MAE B0	MAE ratio	MAE log(ratio)	RMSE B0	RMSE ratio	RMSE log(ratio)	ratio vs B0	log(ratio) vs B0
k1	1,140	0,935	0,918	1,779	1,310	1,380	17,94%	19,44%
k2	1,086	0,831	0,812	1,672	1,203	1,266	23,49%	25,21%
k3	1,092	0,837	0,816	1,680	1,192	1,261	23,35%	25,30%
x̄:	1,106	0,868	0,849	1,711	1,235	1,302	21,54%	23,26%

Ilustración 42: Resultados validación para el modelo Ridge

Las dos versiones mejoran a B0 en los 3 folds. El error es estable entre folds, k1 es el fold con más error en ambas versiones. Con los datos disponibles no se puede saber si la diferencia se debe al menor volumen de entrenamiento o a algo propio de ese mes.

En MAE, la métrica principal, el entrenamiento con el logaritmo mejora levemente al del ratio en los 3 folds. En RMSE ocurre lo contrario, el ratio mejora a log(ratio) en los 3 folds. En ambos casos se mantienen errores grandes en una parte de las fases, en línea con la cola del ratio vista en el análisis de la variable objetivo.

Métrica	Ratio real	Ratio inferido	Log(ratio) inferido
Media	1,968	1,877	1,573
Mediana	1,550	1,871	1,516

Ilustración 43: Descripción de la media y mediana para el ratio real y las inferencias

En validación, la media de las predicciones de la versión log(ratio) se acerca más a mediana del ratio real. En cambio la versión inferida del ratio da una media más

parecida a la del ratio real. El prototipo está pensado para estimar la desviación de cada fase de forma individual. Esto refuerza la elección de MAE como métrica principal para el estudio, ya que mide cuánto se equivoca el modelo en la fase típica. Con este criterio, la versión log(ratio) es la mejor versión de Ridge.

Random Forest (RF)

Random Forest es el primer modelo basado en árboles de la comparación. El objetivo es comprobar si el modelo es capaz de captar relaciones no lineales que mejoren la estimación respecto a Ridge y el baseline.

Un árbol de decisión divide las fases en grupos mediante preguntas sucesivas sobre las variables. Cada grupo final recibe como predicción el valor medio del ratio predicho en las fases de entrenamiento. Un único árbol es fácil de interpretar, pero es inestable, pequeños cambios en los datos producen árboles muy distintos. Por eso en Random Forest se usan combinaciones de muchos árboles. Cada árbol usa una muestra aleatoria de las fases y de las variables. La predicción final es la media de todos los árboles. Al promediar, se reduce la inestabilidad de un árbol individual. El resultado puede llegar a ser más preciso con datos nuevos.

Este modelo encaja con el problema por varios motivos. El análisis de la variable objetivo mostró que el ratio disminuye con la duración de la fase, pero no de forma lineal. Sube mucho en las fases cortas y se estabiliza en las largas. Los árboles captan este tipo de relación sin necesidad de transformar las variables. El efecto de una máquina puede depender del tipo de fase o de la duración. Ridge no modela estas interacciones salvo que se definan explícitamente, mientras que los árboles si las captan.

En la libreria sklearn, para Random Forest las variables categóricas se codifican de forma ordinal en lugar de con one-hot. A simple vista no parece lo más adecuado, porque las categorías no siguen ningún orden. Sin embargo, el árbol no hace cálculos con ese número, solo lo usa para decidir dónde cortar en cada nivel. Así no hace falta crear una columna para cada categoría. Esta codificación tiene un inconveniente. Un solo corte no puede agrupar categorías que no estén seguidas en la numeración. El árbol puede llegar a separarlas, pero necesita más cortes y es menos eficiente.

Igual que con Ridge, el modelo se entrena con ratio y con log(ratio), y en la versión log(ratio) las predicciones se devuelven a escala ratio antes de calcular las métricas.

- *Experimentar con los Hiperparámetros Random Forest*

El número de árboles se fija en 300 y no se ajusta. El hiperparámetro ajustado es *min_samples_leaf*, es el que más influye en el resultado e indica el número mínimo de fases que debe tener cada hoja del árbol. Se han probado los valores 1, 5, 10, 20, 30, 40 y 50 con los 3 folds temporales. El criterio de elección es el menor MAE medio en validación. Además, se calcula el MAE en entrenamiento para detectar sobreajuste.

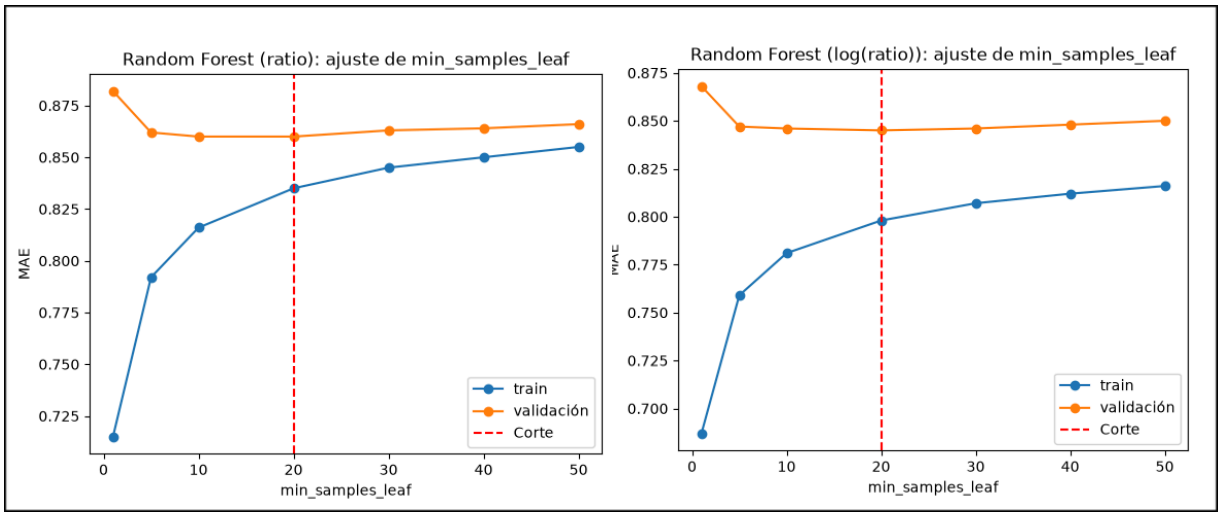


Ilustración 44: Evolución del hiperparámetro para las hojas del árbol.

Las dos versiones muestran el mismo patrón. El error en validación baja claramente entre 1 y 5 y a partir de ahí se mantiene casi plano. El error en entrenamiento sube a medida que crecen las hojas, y la diferencia con validación se reduce. A partir de 5, el valor exacto apenas cambia para el error en validación.

En la versión ratio, el mínimo en validación se alcanza con 20. En la versión log(ratio), el mínimo en validación también está en 20, aunque el error es casi idéntico para 10 y 30. Se adopta *min_samples_leaf* = 20 en ambas versiones.

- *Validación Random Forest*

fold	MAE B0	MAE ratio	MAE log(ratio)	RMSE B0	RMSE ratio	RMSE log(ratio)	ratio vs B0	log(ratio) vs B0
k1	1,140	0,913	0,904	1,779	1,302	1,376	19,88%	20,64%
k2	1,086	0,832	0,819	1,672	1,214	1,279	23,38%	24,53%
k3	1,092	0,820	0,802	1,680	1,179	1,247	24,93%	26,60%
x̄:	1,106	0,855	0,842	1,711	1,231	1,301	22,69%	23,88%

Ilustración 45: Resultados validación para el modelo Random Forest

La versión del logaritmo tiene menor MAE en los 3 folds. La ventaja es pequeña, pero se repite en todos los folds. En RMSE ocurre lo contrario, la versión ratio es mejor en los 3 folds. Igual que en Ridge, las dos métricas no coinciden. Se refuerza la idea que la versión logarítmica reduce el error en la fase típica, pero se equivoca más en las fases con desviaciones grandes.

Como el MAE es la métrica principal, log(ratio) es la mejor versión de Random Forest. La transformación logarítmica mantiene su ventaja también en un modelo no lineal.

LightGBM

Igual que Random Forest, Gradient Boosting también combina muchos árboles, pero aquí se construyen uno detrás de otro. Cada árbol nuevo se entrena para corregir los errores de los anteriores. De las implementaciones disponibles se ha elegido LightGBM.

Las variables categóricas se pasan al modelo como tipo categoría. LightGBM puede agrupar en un mismo corte categorías que no siguen ningún orden. Así se evita la limitación de la codificación ordinal de Random Forest, donde un corte sólo podía agrupar categorías seguidas en la numeración. Las variables numéricas se usan sin transformar.

Se sigue el mismo diseño que con Ridge y Random Forest: dos versiones del modelo, con ratio y con log(ratio), y los 3 folds temporales. Además se probarán las funciones de pérdidas L1 y L2.

L2 si se entrenan en ambas formulaciones del ratio, pero con log(ratio) no se entrena la combinación de L1, porque no aportaría una alternativa distinta a la del ratio. La pérdida L1 hace que el modelo apunte a la mediana de la variable objetivo. A diferencia de la media, la mediana no cambia al aplicar el logaritmo. Ordenar las fases por su ratio o por su logaritmo da el mismo orden, y la fase que queda en el centro es la misma. Al deshacer la transformación logarítmica con la exponencial, el ratio que se recupera es el la mediana del ratio. Por tanto, L1 sobre log(ratio) estimaría la misma cantidad que L1 sobre el ratio. En cambio, L2 sobre log(ratio) apunta a la media del logaritmo, que en escala ratio equivale a la media geométrica. Esta queda próxima a la mediana, pero no coincide con ella, por lo que sí constituye una opción distinta que merece compararse.

- *Experimentar con los Hiperparámetros LightGBM*

La tasa de aprendizaje se fija en 0,05 en todos los experimentos. Se ajustan *num_leaves* (número máximo de hojas de cada árbol) y *min_child_samples* (número mínimo de fases por hoja), con el número de árboles fijo a 500. Después, con esos dos valores fijos, se ajusta el número de árboles (*n_estimators*).

En todos los casos se elige la combinación con menor MAE medio en validación. Se han probado primero *num_leaves* de 4, 7, 10, 15, 30, 45 y 60, combinados con *min_child_samples* de 10, 20, 35 y 50.

Para el error L2 con el ratio se observan los siguientes resultados:

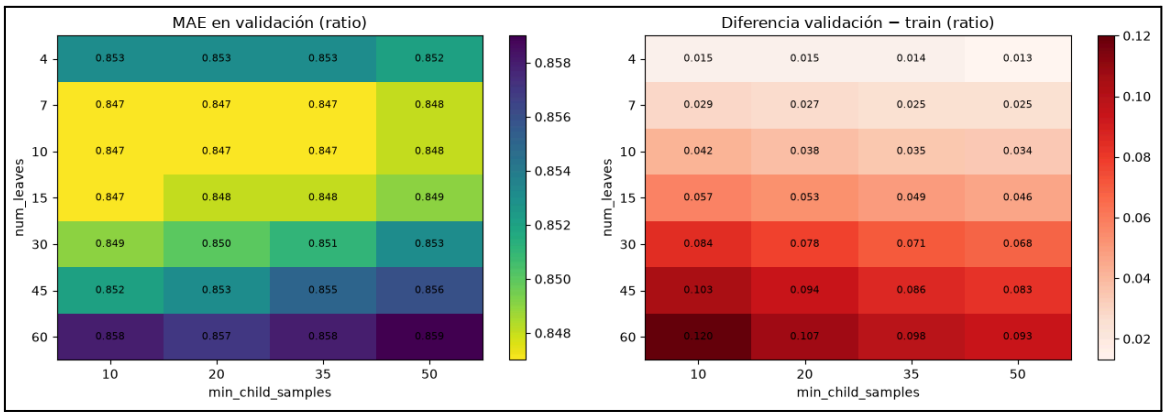


Ilustración 46: Resultados para num_leaves y min_child_samples con L2 ratio

Los dos mapas muestran que *num_leaves* es el hiperparámetro que más influye, *min_child_samples* sólo ajusta en base a este. En validación, el MAE forma una meseta entre 7 y 15 hojas. Con 4 hojas el modelo se queda corto y a partir de 30 empeora progresivamente.

La diferencia entre validación y entrenamiento crece con el número de hojas, los árboles más grandes se ajustan más al entrenamiento sin mejorar en validación. Subir *min_child_samples* reduce esa diferencia, sobre todo en los árboles grandes, pero a partir de 30 hojas lo hace a costa de empeorar el error en la validación.

Se adopta *num_leaves* = 7 y *min_child_samples* = 35 ya que tiene el menor MAE en validación (0,847) y la menor diferencia con el entrenamiento (0,025) entre las combinaciones que lo empatan.

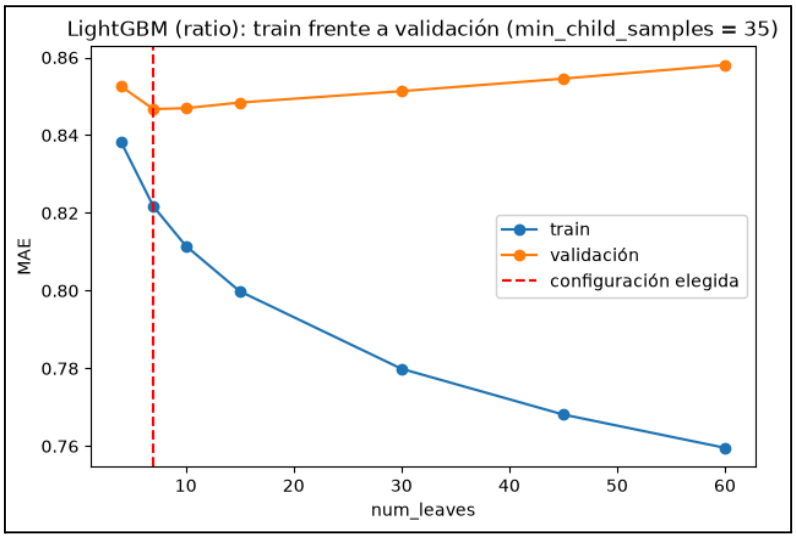


Ilustración 47: Resultados de num_leaves con L2 ratio

Evaluando ahora el *n_estimators* se obtiene el mejor resultado con 750 a un *learning rate* de 0,05.

Para el error L2 con el ratio se observan los siguientes resultados:

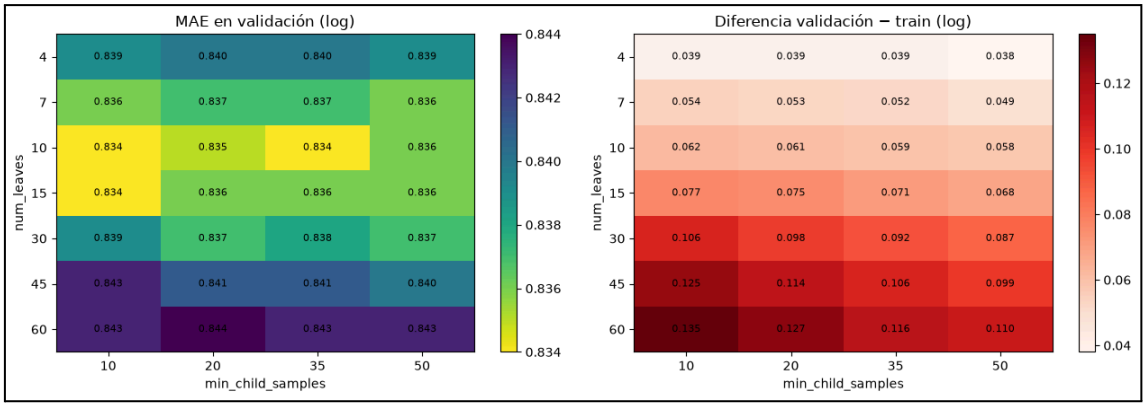


Ilustración 48: Resultados para num_leaves y min_child_samples con L2 log(ratio)

El comportamiento general es parecido al de la versión ratio, *num_leaves* es el hiperparámetro que más influye, con 4 hojas el modelo se queda corto y a partir de 30 empeora progresivamente. Sin embargo, la meseta se desplaza hacia árboles algo mayores, el menor MAE en validación se alcanza con 10 hojas.

Se aplica el mismo criterio que en la versión ratio, el menor MAE en validación y, entre las combinaciones que lo empatan, la menor diferencia con el entrenamiento. Se adopta *num_leaves* = 10 y *min_child_samples* = 35.

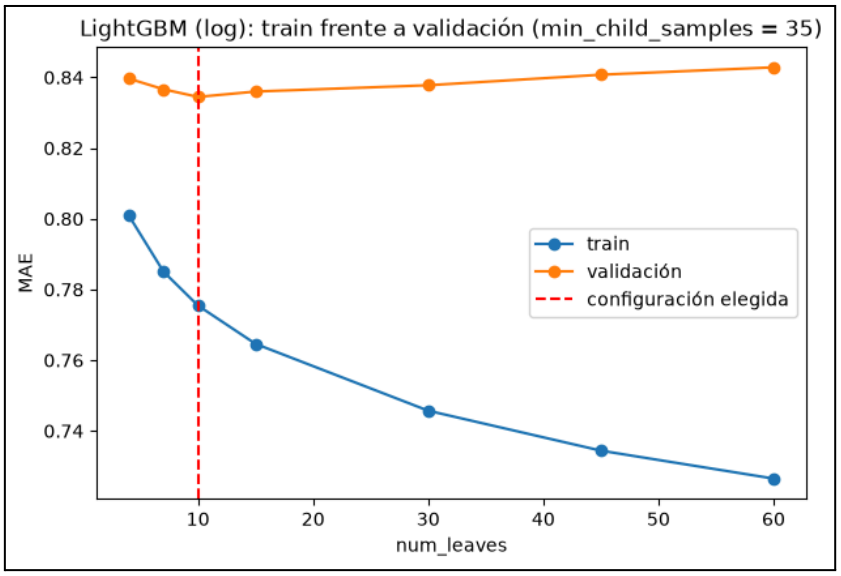


Ilustración 49: Resultados de num_leaves con L2 log(ratio)

La diferencia entre validación y entrenamiento es mayor que en la versión ratio para el mismo tamaño de árbol, y crece igualmente con el número de hojas. A diferencia de la versión ratio, ninguna combinación obtiene a la vez el menor error y la menor diferencia.

Para *n_estimators* el MAE en validación mejora de 250 a 500 árboles y a partir de ahí empeora en un punto. El error en entrenamiento sigue bajando y la diferencia con validación crece. Los árboles adicionales solo memorizan. A diferencia de la versión ratio, que con árboles de 7 hojas necesitaba 750, aquí los árboles son algo mayores (10 hojas) y cada uno corrige más error, por lo que el óptimo se alcanza antes. Se adopta *n_estimators* = 500.

Ahora se prueba la función de pérdida L1, que minimiza el error absoluto: todos los errores pesan igual, sin penalizar más los grandes. Con L1 la predicción apunta a la mediana.

Para el error L1 con el ratio se observan los siguientes resultados:

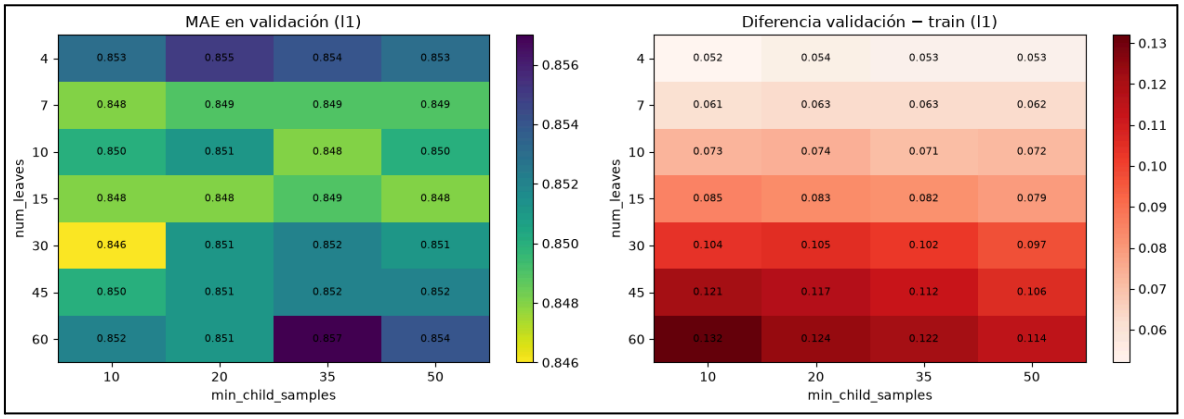


Ilustración 50: Resultados para num_leaves y min_child_samples con L1 ratio

A diferencia de las versiones L2, el mapa de MAE en validación de L1 es irregular: no se aprecia una meseta clara y el mejor resultado, 30 *hojas* y *min_child_samples* = 10, aparece aislado, rodeado de combinaciones con peor error. La diferencia entre validación y entrenamiento sigue el mismo patrón que en L2, creciendo con el número de hojas, pero es mayor para el mismo tamaño de árbol.

Aunque los resultados son cercanos a L2, ninguna combinación de L1 mejora a las versiones de L2 obtenidas. Por ende se descarta L1.Ilustración 52: Resumen de las distintas opciones de LightGBM

- *Validación LightGBM*

versión	Número hojas	Mínimo de filas por hoja	Número de árboles	MAE medio	RMSE medio
L2 ratio	7	35	750	0.845	1.216
L2 log(ratio)	10	35	500	0.834	1.289
L1 ratio (descartada)	30	10	500	0.846	1.317

Ilustración 51: Posibles configuraciones con resultados LightGBM

fold	MAE B0	MAE ratio	MAE log(ratio)	RMSE B0	RMSE ratio	RMSE log(ratio)	ratio vs B0	log(ratio) vs B0
k1	1,140	0,901	0,897	1,779	1,281	1,359	20,90%	21,28%
k2	1,086	0,813	0,800	1,672	1,187	1,256	25,11%	26,30%
k3	1,092	0,822	0,806	1,680	1,181	1,254	24,76%	26,16%
x̄:	1,106	0,845	0,834	1,711	1,216	1,289	23,55%	24,53%

Ilustración 52: Resultados validación para el modelo LightGBM

De nuevo, la versión logarítmica tiene menor MAE en los 3 folds. En RMSE también ocurre lo contrario, la versión ratio es mejor en los 3 folds. Es lo mismo que pasaba en Ridge y en Random Forest. La versión log reduce el error en la fase típica, pero se equivoca más en las fases con desviaciones grandes. Febrero vuelve a ser el fold con más error. Como el MAE es la métrica principal, log(ratio) es la mejor versión de LightGBM.

4.4.6 Comparaciones

En este apartado se comparan los seis modelos entrenados (Ridge, Random Forest y LightGBM, cada uno con ratio y con logaritmo usando las predicciones de validación de los 3 folds. El objetivo es elegir el modelo final antes de pasar los datos de test.

En validación se calcula con la media de los 3 folds y sirve para seleccionar el modelo.

Además de B0 se usan otros tres baselines, que no forman parte de la hipótesis y solo sirven para valorar cuánto aporta el modelo.

Modelo con MAE	k1	k2	k3	Media
pred_lgbm_log	0,897	0,800	0,806	0,834
pred_rf_log	0,904	0,819	0,802	0,842
pred_lgbm_ratio	0,901	0,813	0,822	0,845
pred_ridge_log	0,918	0,812	0,816	0,849
pred_rf_ratio	0,913	0,832	0,820	0,855
pred_ridge_ratio	0,935	0,831	0,837	0,868
B2-máquina	0,978	0,890	0,922	0,930
B2-familia	0,988	0,900	0,937	0,942
B1	1,021	0,928	0,967	0,972
B0	1,140	1,086	1,092	1,106

Ilustración 53: Tabla resumen de MAE para los modelos y los baselines en cada fold

Para la media global los seis modelos presentan menor MAE y menor RMSE que todos los baselines en los 3 folds. Esto incluye a B2-máquina, el baseline más exigente.

En MAE la versión log(ratio) es mejor que la versión ratio en los tres modelos y en los tres folds. El menor MAE medio es el de LightGBM-log, seguido de RF-log y LightGBM-ratio. Este orden no se mantiene en todos los folds.

En RMSE ocurre lo contrario, la versión ratio es mejor en los tres modelos y en los tres folds.

Esta diferencia está en línea con la media de las predicciones en validación, las versiones log(ratio) predicen valores más cercanos a la fase típica.

La hipótesis del trabajo define que el modelo mejora la planificación actual del ERP en al menos un 20 %. Para medirlo se usa el skill score de MAE frente a B0:

$$skill = 1 - MAE_modelo / MAE_B0$$

Modelo MAE	vs B0	vs B1	vs B2-familia	vs B2-máquina
LightGBM-log	24,5%	14,2%	11,4%	10,3%
RandomForest-log	23,9%	13,4%	10,6%	9,5%
LightGBM-ratio	23,6%	13,0%	10,2%	9,1%
Ridge-log	23,3%	12,7%	9,9%	8,7%
RandomForest-ratio	22,7%	12,1%	9,2%	8,1%

Ridge-ratio	21,5%	10,7%	7,9%	6,7%

Ilustración 54: Tabla resumen del skill score para cada modelo frente los baselines

Con la media de los 3 folds, todos los modelos superan el umbral del 20 % frente a B0. Frente a B1, B2-familia y B2-máquina la mejora es menor, pero positiva en todos los casos. Antes de elegir el modelo se revisa si el skill score se mantiene en cada fold y no solo en la media. Esto solo para B0:

Modelo	**k1**	**k2**	**k3**	**Media**
LightGBM-log	21,3%	26,3%	26,2%	24,5%
RandomForest-log	20,6%	24,5%	26,6%	23,9%
LightGBM-ratio	20,9%	25,1%	24,8%	23,6%
Ridge-log	19,4%	25,2%	25,3%	23,3%
RandomForest-ratio	19,9%	23,4%	24,9%	22,7%
Ridge-ratio	17,9%	23,5%	23,4%	21,5%

Ilustración 55: Tabla resumen del skill score para B0 en cada fold

Febrero es el fold con menor skill score en todos los modelos. Solo LightGBM-log, LightGBM-ratio y RF-log superan el 20 % en los tres folds. Calculando el skill score frente a B1, B2-familia y B2-máquina, para cada fold, se obtiene que el skill score es positivo en todos los modelos y en todos los folds. LightGBM-log tiene la mayor media frente a los cuatro baselines.

Se elige LightGBM con log(ratio) como modelo final. Este tiene el menor MAE medio en validación (0,834). Su skill score de MAE frente a B0 supera el 20 % en los tres folds. Frente a B2-máquina, el baseline más exigente, reduce el MAE un 10,3 % de media.

Se prioriza el MAE porque el objetivo es mejorar la planificación en la fase típica. El MAE pondera cada error según su tamaño y está alineado con la mediana, así que no lo dominan las fases con desviaciones extremas. El RMSE penaliza más los errores grandes y se ha usado como complemento. Elegir log(ratio) supone aceptar un peor comportamiento en las desviaciones grandes a cambio de un menor error en la fase típica.

4.5 Evaluación

En este apartado se evalúan los modelos sobre el conjunto de test. Este conjunto lo forman las fases de las órdenes de fabricación de mayo, junio y julio del 2026. Estas fases no se han usado ni para entrenar ni para elegir el modelo. Tampoco se han utilizado para calcular los baselines.

4.5.1 Métricas MAE y RMSE los modelos

Los seis modelos, con los hiperparámetros que se fijaron en validación, se entrenan para todo el periodo de desarrollo y después predicen las fases en test. Todos los modelos ahora se evalúan en test, solo para poder comparar resultados, la elección ya está tomada. El modelo final, LightGBM con log(ratio), fue elegido como la mejor opción con los datos de validación. Esta elección no se cambia independientemente de los resultados obtenidos en test. Las métricas y los baselines son los mismos que en validación.

Los modelos y los baselines quedan ordenados de la siguiente manera según su MAE, con la predicción aprendida en desarrollo y enfrentada a los datos de test:

Modelo	MAE		Modelo	RMSE
LightGBM-log	0,786		RandomForest-ratio	1,175
RandomForest-log	0,790		LightGBM-ratio	1,186
Ridge-log	0,798		Ridge-ratio	1,208
RandomForest-ratio	0,816		LightGBM-log	1,131
LightGBM-ratio	0,829		RandomForest-log	1,134
Ridge-ratio	0,836		Ridge-log	1,156
B2-máquina	0,862		B2-máquina	1,262
B2-familia	0,882		B2-familia	1,285
B1	0,904		B1	1,316
B0	1,019		B0	1,585

Ilustración 56: MAE y RMSE en test para cada modelo y baseline

Los seis modelos tienen menor MAE y menor RMSE que todos los baselines. Pasa lo mismo que en validación: en MAE, la versión log(ratio) es mejor que la versión ratio en los tres modelos, y en RMSE ocurre lo contrario. El menor MAE vuelve a ser el de LightGBM-log, confirmando el resultado obtenido en validación.

Debido a la naturaleza del problema interesan más los resultados de MAE, ya que inciden en la mediana, lo cual representa el ratio de una fase media.

4.5.2 Skill score MAE

El skill refleja el porcentaje de mejora de modelos para cada baseline respecto el MAE. Es una forma de medir la mejora en el error medio.

Modelo	vs B0	vs B1	vs B2-familia	vs B2-máquina
LightGBM-log	23%	13,1%	11%	9%
RandomForest-log	22,5%	12,7%	10,4%	8,3%
Ridge-log	21,7%	11,7%	9,5%	7,4%
RandomForest-ratio	19,9%	9,8%	7,4%	5,3%
LightGBM-ratio	19,6%	9,4%	7,1%	5%
Ridge-ratio	18%	7,6%	5,2%	3%

Ilustración 57: Skill score MAE de cada modelo frente los baselines para test

En el conjunto de prueba, el modelo final, LightGBM con log(ratio) como objetivo, alcanza una mejora del 23% en el error absoluto medio respecto a B0. Este valor supera el umbral del 20% fijado antes de obtener los resultados.

Solo las versiones con log(ratio) superan dicho umbral, a diferencia de lo observado en validación, donde lo superan todos los modelos. Las versiones con el ratio como objetivo se sitúan por debajo. Frente a B2-máquina, la referencia más exigente, LightGBM-log reduce el error absoluto medio un 9%.

4.5.3 Interpretabilidad de LightGBM-log

Como se ha demostrado LightGBM-log presenta los mejores resultados para el problema del prototipo que aborda este trabajo. En el próximo apartado se indagará más en los resultados del mismo por segmentos, ahora interesa profundizar en su naturaleza.

Evolución del error

Interesa estudiar cómo se comporta la evolución del error. Para ello se aplica el modelo a todos los meses, incluido los de desarrollo, y se obtiene el error, comparándolo con el de B0.

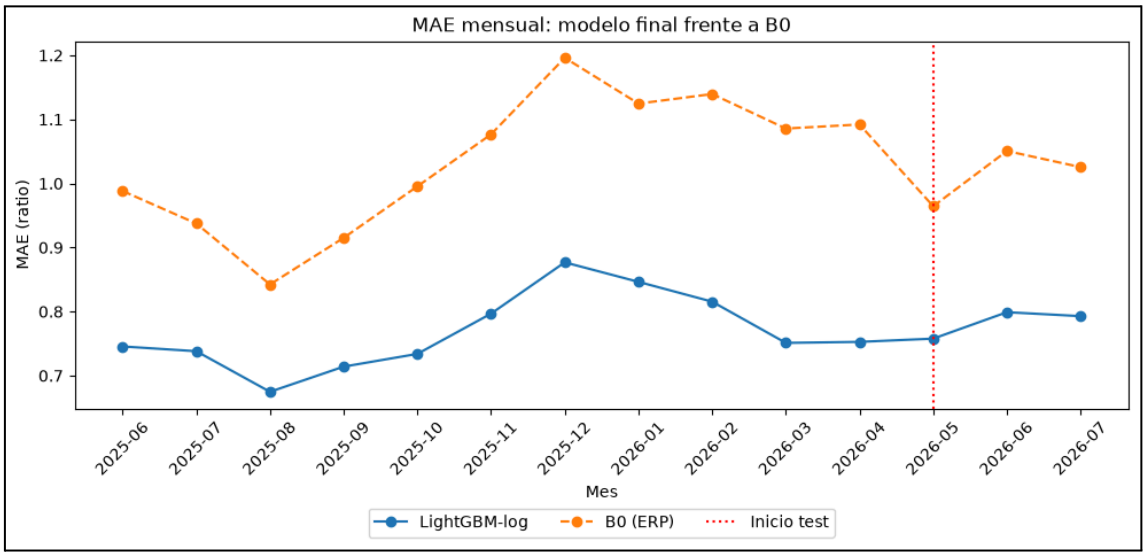


Ilustración 58: Evolución del error para los 14 meses

Hay que tener en cuenta que, a la izquierda de la línea roja, el modelo (línea azul) predice meses que ha utilizado en el entrenamiento, por lo que ese error está dentro de muestra y tiende a ser optimista. A la derecha, el error corresponde a meses no vistos, los meses de test. La línea naranja representa B0, este no se entrena, de modo que su error es comparable en todos los meses.

La línea de B0 señala los meses más difíciles de predecir. El tramo de noviembre a febrero es el más difícil, con el máximo en diciembre, y agosto el más sencillo. El error del modelo sube y baja en los mismos meses que el de B0, lo que sugiere que la variación mensual de su error se debe principalmente a la dificultad de cada mes y no a un comportamiento distinto del modelo.

En los meses de test, el error absoluto medio del modelo se mantiene dentro del rango observado en los meses de desarrollo y próximo al de los últimos meses previos al corte. El error no presenta una tendencia creciente a lo largo del periodo de prueba, lo que indica que el modelo no se degrada en los meses posteriores al entrenamiento.

Peso de las variables

En el modelo LightGBM para poder entender cómo se usa cada variable es necesario emplear SHAP (SHapley Additive exPlanations). SHAP reparte la predicción de cada fase entre las variables de entrada. Cada variable recibe un valor SHAP, que indica cuánto hace subir o bajar la predicción respecto a un valor base.

El análisis se hace sobre el modelo final, LightGBM-log entrenado con todo el periodo de desarrollo, y se aplica a las fases de test. Como el modelo es de árboles, dentro del ecosistema de SHAP se usa TreeExplainer.

El modelo predice log(ratio), así que los valores SHAP están en escala logarítmica:

$$log(ratio\ inferido) = \varphi_0 + \Sigma_i \varphi_i$$

Al deshacer el logaritmo, cada variable actúa como un factor que multiplica el ratio:

$$ratio\ inferido = exp(\varphi_0) \times \Pi_i exp(\varphi_i)$$

Los resultados para las variables se presentan así:

Variable	SHAP	Efecto en el ratio
TiempoPrevisto	0,29	33,34%
TipoFase	0,11	11,61%
Quantity	0,09	9,03%
CodigoMaquina	0,08	8,03%
Família Producto	0,05	5,32%
Familia Maquinas	0,01	1,33%
Línea Producto	0,01	0,95%

Ilustración 59: Resultados del peso de las variables al aplicar SHAP en el modelo

Para el efecto en el ratio los valores recogidos corresponden a la media de los valores SHAP en valor absoluto, expresada en la escala de la variable objetivo.

Indican la magnitud media con la que cada variable desplaza la predicción del modelo respecto al valor esperado, sin distinguir el sentido de ese desplazamiento.

No deben interpretarse como un efecto directo sobre el tiempo real ni como una relación causal, describen el comportamiento del modelo, no el del proceso productivo.

Mostrando los resultados gráficamente se extraen las siguientes conclusiones:

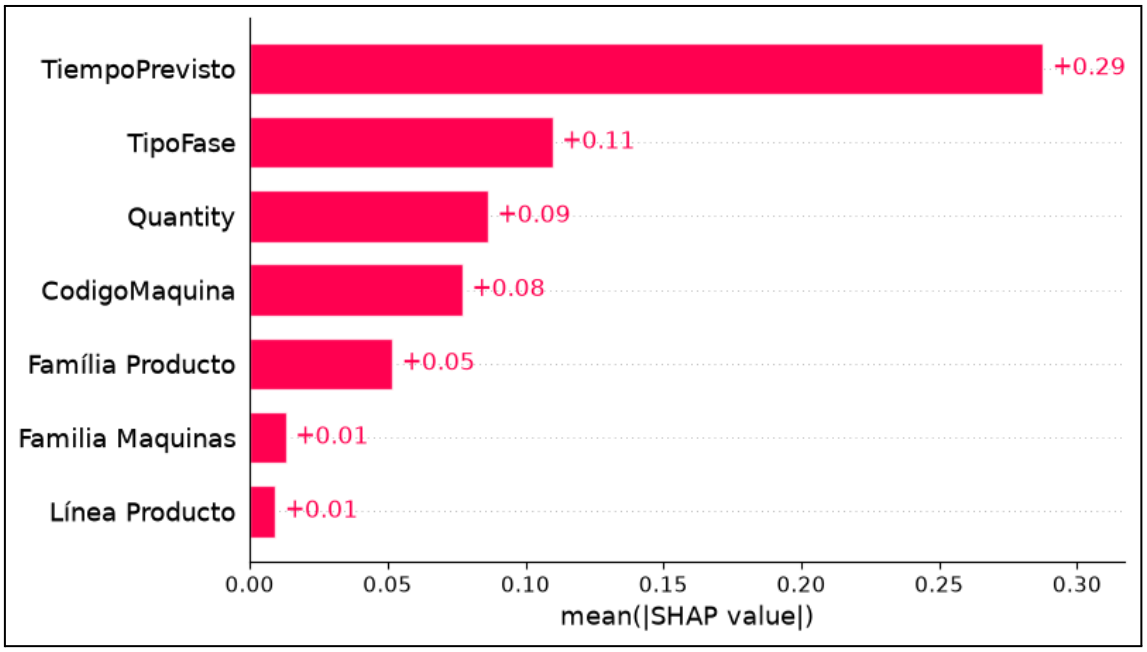


Ilustración 60: Resultados del peso de las variables al aplicar SHAP en el modelo

TiempoPrevisto es la variable con mayor importancia (0,29), muy por encima del resto. Le siguen *TipoFase* (0,11), *Quantity* (0,09) y *CodigoMaquina* (0,08). *Família Producto* tiene una importancia de 0,05, y *Familia Maquinas* y *Línea Producto* de 0,01.

Un valor SHAP positivo hace que el ratio inferido quede por encima de ese valor base, y uno negativo, por debajo.

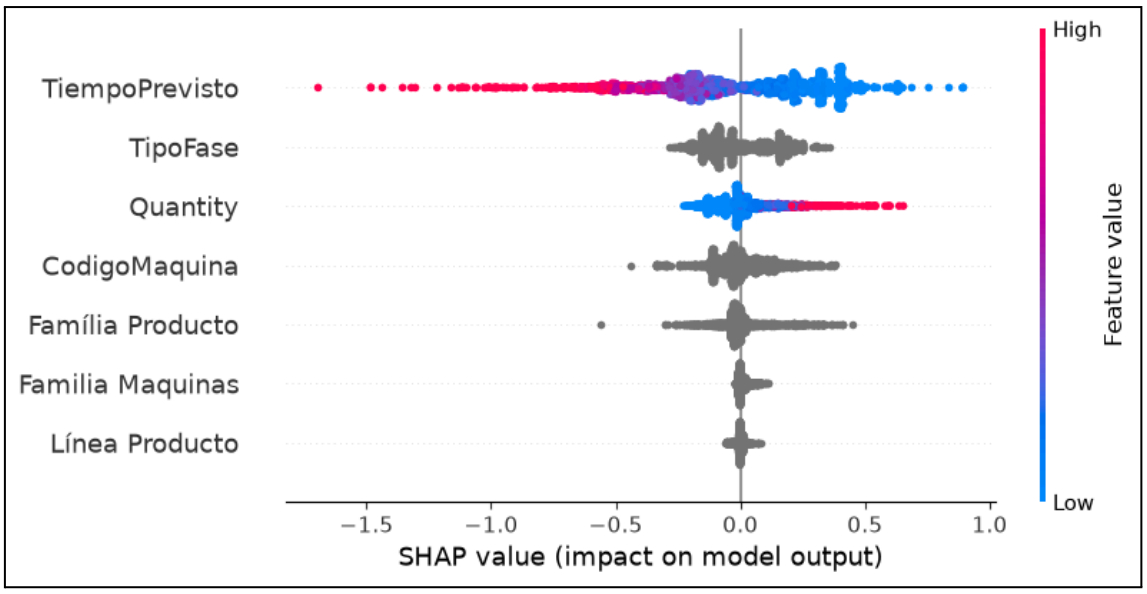


Ilustración 61: Representación de la dirección SHAP hacia la que empuja la variable

Como se ha explicado los valores SHAP muestran cómo usa el modelo cada variable para hacer la predicción. No indican que esa variable cause la desviación en la planta.

El color indica el valor de la variable. El azul para valores bajos y rojo para valores altos. Las variables categóricas aparecen en gris porque no tienen un orden de menor a mayor.

En *TiempoPrevisto*, los valores bajos tienen valores SHAP positivos, es decir, aumentan el ratio inferido. Los valores altos tienen valores SHAP negativos y lo reducen. Además, el efecto no es simétrico: los valores negativos llegan hasta cerca de −1,7, mientras que los positivos no pasan de 0,9. Es la variable con más dispersión en sus valores SHAP. Esto coincide con lo que se vio en el análisis del ratio y lo que se verá en el análisis por tramos de duración. En el próximo apartado se muestra como las fases cortas son las que más se desvían del tiempo previsto.

En *Quantity*, los valores altos tienen valores SHAP positivos, de hasta unos 0,6. Los valores bajos tienen valores SHAP cercanos a 0 o ligeramente negativos. Es decir, la cantidad influye sobre todo cuando es alta, y entonces aumenta el ratio inferido.

TipoFase, *CodigoMaquina* y *Família Producto* tienen valores SHAP positivos y negativos, así que según la categoría aumentan o reducen el ratio inferido. En *TipoFase* los valores se reparten en dos grupos, uno a cada lado de 0. En *Família Producto* la mayoría de las fases están cerca de 0, pero algunas categorías tienen efectos de hasta unos +/- 0,5.

Familia Maquinas y *Línea Producto* tienen valores SHAP concentrados en torno a 0. Su baja influencia se puede explicar por la estructura jerárquica de las variables: cada máquina pertenece a una única familia y cada familia de producto a una única línea. Si el modelo ya conoce *CodigoMaquina* y *Família Producto*, también tiene la información de *Familia Maquinas* y *Línea Producto*, así que estas dos no aportan nada nuevo. Esto no quiere decir que la familia de máquina o la línea de producto no estén relacionadas con la desviación, sino que su efecto ya lo recogen las variables más detalladas.

4.5.4 Análisis por segmentos LightGBM-log

Se procede a analizar el comportamiento del error del modelo ganador, LightGBM-log, en segmentos específicos. Todo para poder obtener conclusiones con más fundamento.

Error por familia de máquinas

Es interesante estudiar el error del modelo frente al error que acumula cada familia de máquinas. Esto se da obteniendo la media del error MAE para el modelo y los baselines en cada familia.

Fam. Máq.	MAE modelo	MAE B0	MAE B1	MAE B2-fam	MAE B2-maq
TPU	0,857	1,246	1,073	1,051	0,985
MTP	0,933	1,144	0,965	0,956	0,954
CV	0,782	1,047	0,910	0,909	0,907
TCN	0,468	0,493	0,537	0,476	0,476
CH	0,527	0,556	0,672	0,578	0,587
C5	0,889	1,201	1,005	1,042	1,044
CV-ALU	0,517	0,575	0,669	0,572	0,574
CON	0,891	0,867	0,893	0,843	0,849
FLEX	0,574	0,683	0,461	0,540	0,532

Ilustración 62: Distribución del error por familia de máquinas en test

A su vez también es útil observar el skill score a nivel de familia:

Fam. Máq.	skill vs B0	skill vs B1	skill vs B2-fam	skill vs B2-maq
TPU	31,23%	20,17%	18,49%	13,04%
MTP	18,45%	3,28%	2,39%	2,20%
CV	25,26%	14,07%	13,93%	13,73%
TCN	5,03%	12,84%	1,73%	1,69%
CH	5,22%	21,64%	8,91%	10,23%
C5	25,93%	11,45%	14,64%	14,83%
CV-ALU	10,17%	22,76%	9,72%	9,96%
CON	-2,81%	0,16%	-5,70%	-5,04%
FLEX	15,98%	-24,34%	-6,17%	-7,86%

Ilustración 63: Distribución del skill score por familia de máquinas en test

La mejora del modelo frente al ERP no es igual en todas las familias. Es mayor en las familias donde el ERP se equivoca más (TPU, C5 y CV; con MAE de B0 por encima de 1). En TPU y CV, unas de las familias con más fases, el modelo supera claramente el

20% frente a B0. En las familias donde el ERP ya se equivoca poco (TCN, CH y CV-ALU), la mejora frente a B0 es pequeña porque hay menos error que corregir.

El punto débil es MTP. Es la segunda familia por volumen, se queda por debajo del 20% frente a B0 y apenas mejora a B1 y a B2 (entre un 2,2 % y un 3,3 %). En esta familia el modelo aporta poco más que una corrección por grupo.

En TCN, CH y CV-ALU, corregir el sesgo con un único valor global (B1) empeora la planificación del ERP. En cambio, el modelo mejora a B0 y a B1 en esas tres familias. Esto indica que el modelo ajusta la predicción según la familia y no aplica la misma corrección a todas las fases.

En CON y FLEX el modelo no mejora a todas las referencias: en CON tiene skill negativo frente a B0 y a B2, y en FLEX B1 obtiene el menor error. Son grupos con pocas fases (53 y 42), así que estos mismos no permiten sacar conclusiones firmes.

Comportamiento del modelo con datos no vistos

Durante la partición de los datos se localizaron dos máquinas en el conjunto de test sin representación en train. Esto permite ver cómo se comporta el modelo con una máquina que no conoce.

Como no hay datos de las máquinas en desarrollo, B2-máquina no tiene valor propio para estas y usa la constante de B1 como sustituto.

Maq.	**MAE modelo**	**MAE B0**	**MAE B1**	**MAE B2-fam**	**MAE B2-maq**
CM19	1,029	1,471	1,190	1,180	1,190
CM18	0,741	0,142	0,329	0,208	0,329
Media de las demás máquinas	0,782	1,013	0,901	0,878	0,858
Maq.	**skill vs B0**		**skill vs B1**	**skill B2-fam**	**skill B2-maq**
CM19	30,07%		13,57%	12,85%	13,57%
CM18	-423,094%		-125,671%	-256,135%	-125,671%
Media de las demás máquinas	22,81%		13,20%	10,98%	9,93%

Ilustración 64: Tabla comparativa MAE y skill score para la máquina no vista en entrenamiento

Los resultados apuntan a que CM19 es más difícil de predecir que el resto de fases. El ERP tiene un MAE de 1,471 en esta máquina, frente a 1,012 en el resto. El modelo también se equivoca más en CM19 frente al global de máquinas como a la familia concreta.

Aun así, el modelo reduce el error del ERP un 30%, lo que refuerza el hecho que sus tiempos teóricos no son realistas. También mejora a todas las referencias con información, con un skill del 12,8 % frente a B2-familia y del 13,6 % frente a B1 y B2-máquina.

La máquina pertenece a una familia con amplia presencia en los datos, circunstancia que puede favorecer la predicción al apoyarse en el comportamiento de equipos similares. El tamaño de la muestra no permite extraer conclusiones sobre el comportamiento del modelo ante máquinas nuevas, pero el resultado sugiere una línea de verificación.

Por otro lado la máquina CM18 solo cuenta con una única instancia en todo el conjunto de datos, sus skill score son extremos, no pueden sacarse conclusiones al respecto.

Error por duración de fase

Las fases se agrupan en cinco tramos de tamaño parecido (quintiles) según el tiempo previsto por el ERP. Se usa el tiempo previsto y no el real porque es el dato que se conoce antes de producir.

Tramo duración (min)	Número de instancias	Ratio medio
[5, 16] muy corta	509	2,22
(16, 32] corta	459	1,69
(32, 70] media	486	1,48
(70, 111] larga	457	1,32
(113, 974] muy larga	474	1,14

Ilustración 65: Agrupación de las fases en test por tramo duración

La duración de las fases en los datos de test va desde un mínimo de 5 minutos hasta un máximo de 974 minutos.

La mediana del ratio baja de forma continua al aumentar la duración. Pasa de 2,22 en las fases más cortas a 1,14 en las más largas. Así se confirma en test lo que ya se vio al estudiar la variable objetivo, las fases cortas tienen desviaciones relativas mayores.

A continuación se estudian los resultados en base a los grupos por duración teórica:

Tramo duración	MAE modelo	MAE B0	MAE B1	MAE B2-fam	MAE B2-maq
[5, 16] muy corta	1,179	1,681	1,399	1,399	1,292
(16, 32] corta	0,901	1,183	1,002	1,002	0,968
(32, 70] media	0,769	0,990	0,886	0,885	0,873
(70, 111] larga	0,603	0,695	0,652	0,682	0,645
(113, 974] muy larga	0,444	0,491	0,541	0,491	0,495

Ilustración 66: Distribución de MAE por tramo duración en las fases de test

Utilizando los resultados de MAE también permite obtener el skill score para facilitar la comprensión de los mismos:

Tramo duración	skill vs B0	skill vs B1	skill vs B2-fam	skill vs B2-maq
[5, 16] muy corta	29,64%	15,51%	11,55%	8,57%
(16, 32] corta	24,06%	10,32%	7,97%	7,20%
(32, 70] media	22,38%	13,36%	13,27%	12,08%
(70, 113] larga	14,25%	8,94%	12,97%	8%
(113, 974] muy larga	9,09%	16,67%	8,52%	9,49%

Ilustración 67: Distribución del skill score por tramo duración en las fases de test

El error de todos los modelos y baselines también baja con la duración. El skill score frente a B0 baja igual, del 29,64% en el tramo más corto al 9,09 % en el más largo, y supera el 20% para las fases *muy cortas*, *cortas* y *medias*. Frente a B2-familia y B2-máquina la mejora es positiva en todos los tramos. En el tramo más largo, B1 tiene más error que B0, seguramente se deba a que una única corrección global sobreestima las fases cuyo ratio típico está cerca de 1.

Entonces se ha determinado que el modelo mejora al ERP en todas las duraciones, pero la mejora es mayor en las fases cortas. En esas fases el ERP es el que más infraestima el tiempo real y hay más errores que corregir. En las fases largas el ERP ya se acerca más al tiempo real y la mejora frente a B0 es menor. Aun así, el modelo sigue mejorando a B1 o B2 en todos los tramos, también en el más largo. Por tanto, el

modelo aporta información más allá de una corrección global o por grupo para todo el rango de duraciones.

Este análisis está hecho en escala ratio y no muestra el impacto en tiempo absoluto. Un error de ratio pesa mucho más en minutos en una fase larga que en una corta. Por eso el siguiente apartado evalúa el error en minutos.

Error en minutos

El modelo predice el ratio de desviación frente al tiempo teórico. Esto permite calcular el tiempo real inferido de forma directa multiplicando el ratio por la variable *TiempoPrevisto* la cual es un atributo de cada fase.

Fórmula	Información
tiempo_real = ratio × TiempoPrevisto	tiempo imputado
tiempo_inferido = ratio_inferido × TiempoPrevisto	tiempo inferido por el sistema
error_minutos = |ratio_inferido − ratio| × TiempoPrevisto	error representado en minutos
error total B0 = Σ error_minutos	indica el % de error total del ERP
min. ahorrados = total_min_B0 − total_min_modelo	diferencia entre minutos de error acumulados ERP y los del modelo

Ilustración 68: Fórmulas para trabajar desde el ratio a minutos

Para el skill score se calcula como:

$$skill = 1 - MAE_min_modelo \,/\, MAE_min_B0$$

Baselines	MAE minutos	skill del modelo
Modelo	41,9 min	0,0%
B0	50,3 min	16,6%
B1	50,8 min	17,4%
B2-fam	48,5 min	13,5%
B2-maq	47,7 min	12,2%

Ilustración 69: Descripción del error en minutos para el modelo y cada baseline

En minutos, el modelo se equivoca de media 41,9 min por fase, frente a los 50,3 min del ERP. Eso supone un skill score del 16,6%. El modelo también mejora a B1, B2-familia y B2-máquina.

B1 tiene un error algo mayor que B0 (50,8 min). Esto está relacionado con el sesgo que corrige ese baseline. B1 aplica la misma corrección a todas las fases, y esta corrección resulta excesiva en las fases largas, cuyo ratio está próximo a 1 y que acumulan la mayor parte de los minutos de error. El resultado es coherente con un tiempo fijo por fase que el ERP no contempla, pesa mucho en las fases cortas y poco en las largas, algo que un factor multiplicativo único no puede corregir.

El mismo estudio aplicado a cada fase permite evaluar los resultados de test en minutos, para las agrupaciones de fases antes definidas. Los valores para MAE se presentan en minutos:

Tramo duración (min)	MAE modelo	MAE B0	MAE B1	error total B0	min. ahorrados
[5, 16] muy corta	15,19	21,63	17,97	9,16%	3281,89
(16, 32] corta	21,42	28,51	24,17	10,87%	3252,58
(32, 70] media	39,47	50,6	45,45	20,25%	5156
(70, 113] larga	52,60	61,03	57,82	23,37%	3887,84
(113, 974] muy larga	82,28	91,38	109,86	36,35%	4355,83

Ilustración 70: Distribución del error en minutos para cada grupo de fases en base su duración teórica

Esta tabla permite observar cuántos minutos se aleja el modelo y cada baseline respecto el tiempo real. A más larga es la fase mayor son sus minutos en MAE.

El error total del ERP se concentra en las fases muy largas. En cambio, las fases más cortas solo suman el 9,16%. El modelo reduce los minutos de error en los cinco tramos.

La mejora en minutos (16,6%) es menor que en ratio (23%). La mayor mejora relativa del modelo está en las fases cortas, pero esas fases suman una parte pequeña del error total en minutos. Las fases largas acumulan la mayor parte de los minutos de error, y en ellas la mejora relativa es menor.

La hipótesis se definió sobre el ratio y por tanto no cambia. Aun así, este resultado marca un límite al impacto que cabe esperar en tiempo real de planta.

4.6 Despliegue

El trabajo concluye con un prototipo validado, que no llega a implantarse en el sistema productivo de la empresa. Se plantean dos vías de implantación, valoradas con el equipo de producción.

La primera consiste en un script independiente. El usuario introduce manualmente los valores de la fase y obtiene como resultado el ratio previsto. El propio script convierte el ratio a minutos. Esta vía no requiere modificar el sistema de producción y resulta sencilla de poner en marcha, aunque obliga al usuario a localizar los datos de entrada. Algunas variables no figuran en la pantalla de planificación, si bien son accesibles sin dificultad desde otras consultas del sistema.

La segunda incorpora la inferencia dentro del propio ERP, en la interfaz que el usuario ya utiliza. Desde la herramienta de planificación, al asignar una fase a una máquina, el sistema debería ofrecer una acción de consulta que ejecute el modelo. Los valores se obtendrían directamente de la base de datos, sin introducción manual, y el resultado mostraría el ratio previsto y el tiempo estimado correspondiente. Esta vía exige modificar el ERP, por lo que su coste de desarrollo es mayor, pero constituye la forma más natural de uso y la de mayor proyección.

La información necesaria para construir una instancia de inferencia se encuentra disponible en el ERP y requiere una transformación mínima, limitada a la conversión del tiempo teórico a minutos. La máquina de referencia no plantea ambigüedad en este contexto, ya que corresponde a la que el usuario está evaluando. Sí resulta necesario, en cambio, que el sistema advierta cuando alguno de los valores no estuvo presente durante el entrenamiento del modelo, como ocurriría con una máquina de incorporación reciente o con una familia de producto poco frecuente. En esos casos la predicción conserva un valor orientativo y su fiabilidad disminuye.

El prototipo admite dos usos complementarios. En la planificación, permite contrastar la desviación esperada de una misma fase en las distintas máquinas de su familia, antes de decidir la asignación. El tiempo inferido puede sustituir al previsto por el ERP o emplearse para ajustarlo, de modo que la carga asignada a cada máquina refleje mejor el comportamiento observado. Por otro lado, en la elaboración de presupuestos, la inferencia del tiempo previsto puede ayudar a afinar el coste atribuido a cada fase, que de otro modo se calcula sobre un tiempo teórico que la planta no siempre cumple. La literatura ya recoge este uso, la predicción de tiempos de producción se emplea tanto en la planificación como en la estimación de costes [Koblasa y Urban, 2026; Matějka et al., 2026].

Dado el carácter de prototipo de este trabajo, la continuación razonable no es la implantación directa en el sistema productivo. Resulta preferible desarrollar una versión más avanzada del prototipo que supere las limitaciones observadas durante el estudio.

5. Cierre del trabajo

5.1 Conclusiones

El objetivo del trabajo era comprobar si un modelo de aprendizaje automático, entrenado con los datos históricos del ERP y del MES, mejora la estimación de los tiempos de fabricación respecto a la planificación actual que se genera en el ERP. La hipótesis planteada supone que el modelo reduce el error de la planificación en al menos un 20%, medido como skill score de MAE frente a B0, es decir, como la reducción porcentual del MAE del modelo respecto a la planificación del ERP.

El modelo seleccionado en validación, LightGBM entrenado sobre log(ratio) como variable objetivo, obtiene en test un skill score de MAE del 23% frente a B0, por lo que la hipótesis se confirma. Este umbral se fijó antes de evaluar el test, y el resultado es coherente con lo obtenido en validación (24,5 % de media en los tres folds).

Todas las decisiones de preparación que dependen de los datos se tomaron sin información del periodo de evaluación. Los umbrales del filtrado de valores atípicos (criterio IQR sobre el logaritmo del ratio) y la agrupación de las máquinas con menos de 30 fases se calcularon únicamente con el entrenamiento del primer fold y se aplicaron después como reglas fijas a validación y test, igual que ocurriría al usar el modelo en planta.

Sin embargo, el resultado principal debe matizarse en tres aspectos.

En primer lugar, B0 representa la planificación del ERP, pero no es la referencia más exigente. Una simple tabla de consulta con la mediana del ratio por máquina (B2-máquina) ya corrige buena parte del error del ERP. Frente a B2-máquina, el modelo reduce el MAE del modelo en un 8,9% en test. Es decir, la mayor parte de la mejora frente al ERP se debe a corregir el sesgo sistemático de cada máquina, y el modelo aporta una mejora adicional, menor pero consistente, al tener en cuenta la duración prevista, el tipo de fase y el producto.

En segundo lugar, la mejora en ratio no se traslada por igual a minutos. Al expresar el error en tiempo real, el modelo reduce el error medio por fase un 16,6% frente al ERP (41,2 frente a 49,7 minutos) y un 12,2% frente a B2-máquina. La mejora relativa es mayor en las fases cortas, pero son las fases largas las que acumulan más minutos de error. En los tres meses de test, el error acumulado del modelo es unos 20.100 minutos menor que el del ERP, unas 335 horas entre los tres meses.

En tercer lugar, el rendimiento no es igual en todas las familias de máquinas. La mejora frente al ERP es mayor en las familias donde el ERP comete más errores. En cambio, es reducida en las familias en las que el tiempo previsto ya se ajusta bien al real y el margen de mejora es pequeño. En las familias CON y FLEX, con muy pocas

fases, el modelo no mejora a todas las referencias, por lo que estos resultados se interpretan con cautela.

En cuanto a la elección de la variable objetivo, el ratio presenta una distribución muy asimétrica, con una cola larga a la derecha hacia valores altos, y su logaritmo se aproxima a una distribución más simétrica. Esto justifica tanto el uso del logaritmo como variable objetivo como la aplicación del criterio IQR sobre el logaritmo del ratio para detectar valores atípicos, ya que este criterio está pensado para distribuciones aproximadamente simétricas.

Ridge, Random Forest y LightGBM, con su configuración por defecto, aprenden minimizando el error cuadrático. Al elevar el error al cuadrado, un error grande pesa mucho más que varios pequeños, de modo que el modelo desplaza su predicción hacia las fases con ratios muy altos para no pagar ese error. Al entrenar sobre el logaritmo, el modelo apunta a la fase típica, un valor próximo a la mediana, en lugar de a la media. Esto tiene dos consecuencias, observadas en los tres modelos y en todos los folds. La versión log(ratio) obtiene menor MAE, ya que el MAE premia acertar la fase típica, y la versión ratio obtiene menor RMSE, ya que el RMSE premia acertar la media y la versión log se queda corta en las fases de la cola. Dado que el objetivo es mejorar la planificación de la fase habitual, se ha priorizado el MAE y se seleccionó la versión log(ratio).

La ventaja de la versión log(ratio) no se explica solo porque su predicción se acerque a la mediana. Entrenar LightGBM minimizando directamente el error absoluto (L1), que también apunta a la mediana, no mejora a la versión log(ratio) en ninguna de las combinaciones de hiperparámetros probadas, transformar la variable objetivo en una distribución simétrica ha facilitado el aprendizaje del modelo.

Esta elección también es adecuada frente al ruido de los propios datos. Los registros del MES pueden contener tiempos inflados por errores en la imputación (como fases que no se cierran a tiempo) y no todos se eliminan con el filtrado de valores atípicos. Al entrenar sobre log(ratio), estas fases siguen formando parte del entrenamiento, pero pierden peso y no arrastran la predicción de la fase típica. La contrapartida es el sesgo de retransformación, que se analiza en las limitaciones.

Los resultados apuntan a que el límite de la predicción está en la información disponible más que en el modelo. Modelos distintos han obtenido errores parecidos, y el error en validación apenas varía entre configuraciones de hiperparámetros muy diferentes. Con las variables disponibles en el ERP y el MES, gran parte de la variabilidad del tiempo real no puede explicarse.

El modelo final no presenta sobreajuste relevante: la diferencia entre el MAE en entrenamiento y en test es de 0,021. Además, su error en los meses de test queda dentro del rango observado durante el desarrollo, y mantiene la mejora en una máquina incorporada después del periodo de entrenamiento.

El análisis SHAP indica que el tiempo previsto es la variable más influyente, las fases con tiempo previsto bajo se asocian a ratios más altos. Le siguen el tipo de fase, la cantidad y la máquina.

Como resultado colateral del análisis, se observa que el ERP parece no contemplar un tiempo fijo por fase. El ratio disminuye de forma continua con la duración prevista. Este patrón es compatible con la existencia de un tiempo fijo por fase (preparación, carga de pieza, tiempo de registro) que el ERP no recoge. Es un hallazgo que la empresa podría aprovechar sin necesidad de ningún modelo, añadiendo unos minutos fijos a determinar para el tiempo teórico de cada fase.

5.2 Limitaciones

Al entrenar sobre log(ratio) y devolver la predicción a escala ratio mediante la exponencial, el modelo no predice la media del ratio, sino una media geométrica, que siempre es menor o igual que la aritmética y que, al ser el logaritmo del ratio aproximadamente simétrico, se sitúa cerca de la mediana. Es el llamado sesgo de retransformación. Este sesgo no es necesariamente negativo para el objetivo del trabajo. El modelo está pensado para estimar la duración de la fase habitual, y el sesgo procede precisamente de no dejarse arrastrar por las fases con desviaciones extremas. Parte de esas fases desviadas pueden responder a ruido en el registro. Intentar acertar estos casos con ratios más elevados haría al modelo menos preciso en la fase típica. Por esto también se implementó la métrica MAE para el error.

El error mínimo alcanzable está limitado por dos factores. Por un lado, el ruido presente en los registros del MES. Incluso tras el filtrado de valores atípicos, el error del modelo es notable respecto al tiempo real, y parte de ese error no es atribuible al modelo, sino a la calidad del dato de partida. Por otro lado, la ausencia de variables que probablemente influyen en el tiempo real y que hoy no se registran en los sistemas sea un aspecto importante a valorar.

Los hiperparámetros se eligieron comparando numerosas configuraciones sobre los mismos tres folds de validación. Con diferencias de milésimas entre configuraciones, existe cierto riesgo de elegir una que gane por azar en esos meses. El test, evaluado una única vez, permite comprobar que el resultado se mantiene fuera de esos meses.

Los resultados por segmentos con pocas fases, como las familias CON y FLEX o la máquina CM19, se basan en muestras reducidas y deben considerarse orientativos.

El periodo de datos disponible abarca catorce meses, con tres meses de test. Esto no permite evaluar efectos estacionales completos ni la estabilidad del modelo a más largo plazo. Se considera que la cantidad de datos es limitada, no puede afirmarse, pero es posible que a con mayores datos los modelos hubiesen presentado mejoras más significativas.

5.3 Trabajo futuro

Como se ha explicado, este estudio culmina con un prototipo. Los siguientes pasos deberían enfocarse en generar un prototipo nuevo, partiendo de las limitaciones observadas en esta primera versión. Las mejoras más destacables reconocidas podrían ser las siguientes:

Incorporar nuevas variables que hoy no se registran en el ERP ni en el MES, como el el turno laboral, la secuencia de fases en la máquina o el estado de la cola de trabajo. Podría ayudar a mejorar la predicción.

Revisar los tiempos definidos en ERP. Está claro que sistemáticamente hay minutos que el ERP no contempla. Debería estudiarse por máquina o por tipo de fase, y evaluar cuánto error del ERP se corrige únicamente con ese ajuste, sin necesidad de un modelo.

Mejorar la calidad del registro en el MES, en particular las imputaciones que no se cierran a tiempo o que se usan solo para declarar el trabajo como realizado. Esto reduciría el ruido de la variable objetivo y el error mínimo alcanzable. Sería muy interesante poder trabajar con PLC o con sensórica directamente desde las máquinas. De esta forma el sistema MES podría capturar el tiempo real de la máquina, sin errores humanos en el marcaje de tiempo.

Es interesante poder reentrenar y evaluar el modelo con un periodo de datos más largo, para comprobar su estabilidad en el tiempo y la posible existencia de efectos estacionales.

6. Referencias

1. Scholten, B., & Brandl, D. (2022). *The road to integration: A guide to applying the ISA-95 standards in manufacturing*. ISA.

2. IEEE Industrial Electronics Society. (2024). *Transforming manufacturing with AI: From data analytics to the smart factory* [https://www.youtube.com/@ieee-ies]. YouTube.

3. Katuu, S. (2020). Enterprise resource planning: Past, present, and future. *New Review of Information Networking, 25*(1), 37–46. https://doi.org/10.1080/13614576.2020.1742770

4. Oluyisola, O. E., Bhalla, S., Sgarbossa, F., & Strandhagen, J. O. (2022). Designing and developing smart production planning and control systems in the industry 4.0 era: A methodology and case study. *Journal of Intelligent Manufacturing, 33*(2), 311–332. https://doi.org/10.1007/s10845-021-01808-w

5. Gaol, F. L., Deniansyah, M. F., & Matsuo, T. (2023). The measurement impact of ERP system implementation on the automotive industry business process efficiency. *International Journal of Business Information Systems, 43*(3), 429–442. https://doi.org/10.1504/IJBIS.2023.131404

6. Dauzère-Pérès, S., Ding, J., Shen, L., & Tamssaouet, K. (2024). The flexible job shop scheduling problem: A review. *European Journal of Operational Research, 314*(2), 409–432. https://doi.org/10.1016/j.ejor.2023.05.017

7. Đurasević, M., & Jakobović, D. (2018). A survey of dispatching rules for the dynamic unrelated machines environment. *Expert Systems with Applications, 113*, 555–569. https://doi.org/10.1016/j.eswa.2018.06.053

8. Jawad, Z. N., & Balázs, V. (2024). Machine learning-driven optimization of enterprise resource planning (ERP) systems: A comprehensive review. *Beni-Suef University Journal of Basic and Applied Sciences, 13*, Article 4. https://doi.org/10.1186/s43088-023-00460-y

9. de Man, J. C., & Strandhagen, J. O. (2018). Spreadsheet application still dominates enterprise resource planning and advanced planning systems. *IFAC-PapersOnLine, 51*(11), 1224–1229. https://doi.org/10.1016/j.ifacol.2018.08.423

10. Guo, D., Ling, S., Rong, Y., & Huang, G. Q. (2022). Towards synchronization-oriented manufacturing planning and control for Industry 4.0 and beyond. *IFAC-PapersOnLine, 55*(2), 163–168. https://doi.org/10.1016/j.ifacol.2022.04.187

11. Realyvásquez-Vargas, A., & Z-Flores, E. (2021). Manufacturing execution system state-of-the-art: Its evolution and dynamism focused on Industry 4.0. En S. M. Favela-Camacho, H. Molina-Salazar, & L. Rico Pérez (Eds.), *Trends in*

industrial engineering applications to manufacturing process (pp. 255–264). Springer. https://doi.org/10.1007/978-3-030-71579-3_11

12. Kishorre Annanth, V., Abinash, M., & Rao, L. B. (2021). Intelligent manufacturing in the context of Industry 4.0: A case study of Siemens industry. *Journal of Physics: Conference Series, 1969*, Article 012019. https://doi.org/10.1088/1742-6596/1969/1/012019

13. Ghasemi, A., Kabak, K. E., & Heavey, C. (2022). Demonstration of the feasibility of real time application of machine learning to production scheduling. En *2022 Winter Simulation Conference (WSC)* (pp. 3406–3417). IEEE. https://doi.org/10.1109/WSC57314.2022.10015436

14. Roy, D., Srivastava, R., Jat, M., & Karaca, M. S. (2022). A complete overview of analytics techniques: Descriptive, predictive, and prescriptive. En P. M. Jeyanthi, T. Choudhury, D. Hack-Polay, T. P. Singh, & S. Abujar (Eds.), *Decision intelligence analytics and the implementation of strategic business management* (pp. 15–30). Springer. https://doi.org/10.1007/978-3-030-82763-2_2

15. Sekeroglu, B., Ever, Y. K., Dimililer, K., & Al-Turjman, F. (2022). Comparative evaluation and comprehensive analysis of machine learning models for regression problems. *Data Intelligence, 4*(3), 620–652. https://doi.org/10.1162/dint_a_00155

16. Kang, Z., Catal, C., & Tekinerdogan, B. (2020). Machine learning applications in production lines: A systematic literature review. *Computers & Industrial Engineering, 149*, Article 106773. https://doi.org/10.1016/j.cie.2020.106773

17. Koblasa, F., & Urban, M. (2026). Time prediction methods in production — A scoping review of the 21st century so far. *Computers & Industrial Engineering, 213*, Article 111713. https://doi.org/10.1016/j.cie.2025.111713

18. Can, B., & Heavey, C. (2016). A demonstration of machine learning for explicit functions for cycle time prediction using MES data. En T. M. K. Roeder, P. I. Frazier, R. Szechtman, E. Zhou, T. Huschka, & S. E. Chick (Eds.), Proceedings of the 2016 Winter Simulation Conference (pp. 2500-2511). IEEE. https://doi.org/10.1109/WSC.2016.7822289

19. Matějka, M., Dian, M., Lhota, J., Beran, T., & Hlinák, V. (2026). Machine learning regression approaches for manufacturing cost and time prediction: A comprehensive review. Manufacturing Technology, 26(1), 53–62. https://doi.org/10.21062/mft.2026.010

20. Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (1999, March). The CRISP-DM user guide. In *4th CRISP-DM SIG Workshop in Brussels in March* (Vol. 1999, pp. 1-14). sn.

21. Zheng, A., & Casari, A. (2018). *Feature engineering for machine learning: Principles and techniques for data scientists*. O'Reilly Media.

22. Tukey, J. W. (1977). Exploratory data analysis (Vol. 2, pp. 131-160). Reading, MA: Addison-wesley.

23. Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K. R. (2021). Towards CRISP-ML (Q): a machine learning process model with quality assurance methodology. Machine learning and knowledge extraction, 3(2), 392-413.